

GUIA DE SUPERVIVENCIA PARA ESTADÍSTICA, PROBABILIDAD Y REGRESIONES

1. Media (Promedio)

- **Fórmula:**

$$\bar{x} = \frac{\sum x_i}{n}$$

- **Leyenda:**

- $\bar{x}$ (x con un sombrero plano): Representa la media muestral.
- $\sum$ (Sigma mayúscula): Significa "sumatoria". Indica que hay que sumar todo lo que viene a continuación.
- x_i Cada valor individual de nuestro conjunto de datos (cada precio).
- n: El número total de datos que tenemos.
- **Qué hace:** Suma todos los valores y los divide entre el número total de elementos. Busca el "centro de gravedad" matemático.
- **Para qué se usa:** Para tener un valor de referencia rápido sobre un conjunto de datos, aunque es muy sensible a valores extremos (outliers).
- **Cómo se interpreta:** "Si pusiéramos todo el dinero de las ventas en un bote y lo repartiéramos a partes iguales entre todas las casas, este sería el precio de cada una".
- **Ejercicio Real:** * Suma de precios ($\sum x_i$): \$150k + 160k + 165k + 170k + 175k + 180k + 900k = 1.900.000 €\$
 - Cantidad de casas (n): 7
 - Media ($\bar{x}$): \$1.900.000 / 7 = 271.428 €\$
 - *Nota:* Fíjate cómo la media nos dice que el precio promedio es 271.428€, ¡pero 6 de las 7 casas cuestan mucho menos que eso! La villa de lujo ha distorsionado la realidad.

2. Mediana

- **Fórmula:** Valor en la posición $\frac{n+1}{2}$ (solo funciona si los datos están ordenados de menor a mayor). Importante, si la lista contiene datos pares se calcula así:

$$\frac{n}{2} + \frac{n+1}{2}$$

- **Leyenda:** n: Número total de observaciones.
- **Qué hace:** Ordena todos los datos en una fila y elige exactamente el que está en el medio. Divide la muestra en dos mitades idénticas en cantidad.
- **Para qué se usa:** Es la métrica estrella en el sector inmobiliario porque es "robusta". No se deja engañar por casas excesivamente caras o baratas.
- **Cómo se interpreta:** "El 50% de las casas del barrio cuestan menos de este precio, y el otro 50% cuestan más".
- **Ejercicio Real:**
 - Datos ordenados: 150k, 160k, 165k, **170k**, 175k, 180k, 900k.
 - Posición central: $(7 + 1) / 2 = 4$. Buscamos el valor en la 4ª posición.
 - Mediana: **170.000 €**.
 - *Nota:* Este número representa muchísimo mejor lo que cuesta una casa "típica" en esta promoción que la media de 271k.

3. Moda

- **Fórmula:** El valor x_i que tiene la mayor frecuencia absoluta (f_i).
- **Leyenda:** x_i : El valor observado.
 - f_i : Número de veces que aparece ese valor.
- **Qué hace:** Simplemente busca el número que más se repite.
- **Para qué se usa:** No se suele usar mucho con precios exactos (porque es raro que dos casas cuesten el céntimo exacto), pero es vital para variables categóricas (ej. número de habitaciones, código postal más vendido).
- **Cómo se interpreta:** "La característica más popular o frecuente en el mercado es X".
- **Ejercicio Real:**
 - Supongamos que las habitaciones de esas 7 casas son: 2, 3, 3, 3, 4, 4, 5.
 - El número 3 se repite tres veces (la mayor frecuencia).
 - Moda: **3 habitaciones**.

4. Percentiles y Rango Percentil

- **Fórmula Percentil P_k :** $P_k = \text{valor en la posición } \frac{k}{100} \cdot (n + 1)$
- **Leyenda:**
 - P_k : El percentil que estamos buscando (ej. P90 es el percentil 90).
 - k: El porcentaje (de 1 a 99).
 - n: Número total de datos.
- **Qué hace:** Corta los datos ordenados en 100 porciones iguales (la mediana, de hecho, es el percentil 50).
- **Para qué se usa:** Para saber el "estatus" o la posición relativa de una casa frente a todo su mercado.
- **Cómo se interpreta:** Si el percentil 90 es 400.000€, significa que el 90% de las casas cuestan menos de 400.000€ y solo un 10% de élite cuesta más.
- **Ejercicio Real:** * Vamos a buscar el Percentil 25 (el límite de las casas más baratas) en nuestros 7 precios.

$$\text{Posición: } \frac{25}{100} \cdot (7 + 1) = 0.25 \cdot 8 = 2.$$

-
- Buscamos el valor en la posición 2 de nuestra lista (150k, **160k**, 165k...).
- Percentil 25 (P25): **160.000 €**. El 25% de la promoción cuesta 160.000€ o menos.

5. Varianza (Muestral)

- **Fórmula:**
$$s^2 = \frac{\sum (x_i - \bar{x})^2}{n-1}$$
- **Leyenda:**
 - s^2 : Varianza muestral (la 's' viene de *sample*, muestra en inglés).
 - x_i : Cada precio individual.
 - $\bar{x}$: La media que calculamos antes.
 - $n-1$: Se resta 1 a la cantidad de datos (grados de libertad) para corregir el sesgo al usar una muestra en lugar de toda la población mundial.
- **Qué hace:** Mide la dispersión. Calcula a qué distancia está cada casa de la media, eleva esas distancias al cuadrado (para que no haya negativos que se anulen) y hace una especie de promedio de esos cuadrados.
- **Para qué se usa:** Es un paso matemático intermedio necesario para fórmulas más complejas.
- **Cómo se interpreta:** Su interpretación humana es inútil porque el resultado está en "euros al cuadrado".
- **Ejercicio Real:** (Usaremos solo 3 casas para no hacer el cálculo eterno: 150k, 170k, 190k. Su media es 170k).
 - Casa 1: $(150k - 170k)^2 = (-20.000)^2 = 400.000.000\$$
 - Casa 2: $(170k - 170k)^2 = (0)^2 = 0\$$
 - Casa 3: $(190k - 170k)^2 = (20.000)^2 = 400.000.000\$$
 - Suma: 800.000.000\$
 - Dividimos entre $(n-1)$, o sea $3-1 = 2$: $800.000.000 / 2 = 400.000.000 \text{ euros}^2$

Nota: x^2 significa que un valor está elevado al cuadrado.

6. Desviación Típica (Standard Deviation)

- **Fórmula:** $s = \sqrt{s^2}$ (La raíz cuadrada de la fórmula anterior)
- **Leyenda:**
 - s : Desviación típica.
 - $\sqrt{}$: Raíz cuadrada.
- **Qué hace:** Deshace el "cuadrado" de la varianza para devolver los datos a su escala y unidad original (euros normales).
- **Para qué se usa:** Es la métrica reina para medir el riesgo o la volatilidad. Nos dice cuánto "bailan" los precios habitualmente.
- **Cómo se interpreta:** "En promedio, los precios de estas casas se desvían de la media en \$\$\$ euros hacia arriba o hacia abajo".
- **Ejercicio Real:**
 - Cogemos la varianza del paso anterior: \$400.000.000\$.
 - $s = \sqrt{400.000.000} = 20.000€.$
 - Interpretación: El precio medio es 170.000€, con una desviación típica de 20.000€. Lo normal es encontrar casas entre 150k y 190k.

7. Z-Scores (Puntuación Z)

- **Fórmula:** $z = \frac{x_i - \bar{x}}{s}$
- **Leyenda:**
 - z : El z-score.
 - x_i : El precio de la casa específica que estamos evaluando.
 - $\bar{x}$: La media de todas las casas.
 - s : La desviación típica.
- **Qué hace:** Convierte euros a "unidades de desviación". Nos dice a cuántas desviaciones estándar se encuentra una casa concreta respecto a la media.
- **Para qué se usa:** Para estandarizar datos y detectar Outliers matemáticamente. Todo lo que pase de $z = +3$ o baje de $z = -3$ es una anomalía.
- **Cómo se interpreta:** Si una casa tiene un Z de +2.5, es excepcionalmente cara. Si tiene un Z de 0, cuesta exactamente lo mismo que la media.
- **Ejercicio Real:** (Volvemos a nuestra lista de 7 casas, cuya media era 271.428€ y supongamos que su desviación típica calculada es de 255.000€).
 - Evaluamos la Villa de Lujo ($x_i = 900.000$ €).
 - $$z = \frac{900.000 - 271.428}{255.000} = \frac{628.572}{255.000} = +2.46.$$
 - La villa está casi 2.5 desviaciones típicas por encima de la media. ¡Es carísima comparada con su entorno!

8. IQR (Rango Intercuartílico)

- **Fórmula:** $IQR = Q3 - Q1$
- **Leyenda:**
 - Q3: Tercer Cuartil (es exactamente lo mismo que el Percentil 75).
 - Q1: Primer Cuartil (es exactamente lo mismo que el Percentil 25).
- **Qué hace:** Mide la distancia entre el 25% más barato y el 25% más caro. Básicamente, aísla el 50% "del medio" de tus datos.
- **Para qué se usa:** Es la mejor forma de ver la dispersión real ignorando las mansiones extremas o las ruinas baratísimas. También se usa para dibujar diagramas de caja (Boxplots).
- **Cómo se interpreta:** "El 50% central del mercado inmobiliario se mueve en una franja o rango de IQR euros".
- **Ejercicio Real:**
 - Supongamos que en un barrio, Q3 (el P75) es 300.000€ y Q1 (el P25) es 200.000€.
 - $IQR = 300.000 - 200.000 = 100.000 \text{ €}$
 - Interpretación: El grueso del mercado se negocia en una franja de 100.000€ de diferencia.

9. Skewness (Sesgo o Asimetría)

- **Fórmula (Coeficiente de Fisher-Pearson):**

$$G_1 = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^3}{s^3}$$

- **Leyenda:**

- G_1 : Coeficiente de asimetría.
- $\sum (x_i - \bar{x})^3$: Sumamos la distancia de cada casa a la media, pero **elevada al cubo**. Esto es clave: al ser potencia impar, mantiene los signos negativos (casas baratas) y positivos (casas caras).
- n : Número total de casas.
- s^3 : Desviación típica al cubo (para estandarizar la medida).

- **Qué hace:** Mide hacia qué lado está "deformada" la curva de nuestros datos.
- **Para qué se usa:** Para saber si hay una acumulación de datos en precios muy bajos o muy altos. En Real Estate, casi siempre hay un sesgo positivo porque el límite inferior es 0€ (no regalan casas), pero el límite superior es infinito.
- **Cómo se interpreta:**
 - **Sesgo = 0:** Curva simétrica perfecta (campana). Media = Mediana.
 - **Sesgo Positivo (>0):** La "cola" de la gráfica se estira hacia la derecha. Significa que hay unas pocas casas ridículamente caras que tiran de la media hacia arriba (Media > Mediana).
 - **Sesgo Negativo (<0):** La "cola" se va a la izquierda. Hay algunos valores anormalmente bajos.

- **Ejercicio Real (Simplificado):**


Imagina 3 casas: 100k, 120k, 600k. La media es 273k y la desviación $s \approx 283k$.

1. Calculamos distancias al cubo:

- $(100 - 273)^3 = (-173)^3 = -5.177.000$
- $(120 - 273)^3 = (-153)^3 = -3.581.000$
- $(600 - 273)^3 = (327)^3 = +34.965.000$

2. Sumamos: $-5.1M - 3.5M + 34.9M = 26.300.000$.

3. Al ser un número **positivo muy grande**, el resultado final será > 0 . Hay un **fuerte sesgo positivo** por la casa de 600k.



10. Kurtosis (Curtosis o Apuntamiento)

- **Fórmula (Exceso de Curtosis):**


$$K = \left[\frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^4}{s^4} \right] - 3$$

- **Leyenda:**

- K : Coeficiente de curtosis.
- $\sum (x_i - \bar{x})^4$: Distancia de cada casa a la media **elevada a la cuarta**. Al ser potencia par, todo se vuelve positivo y los valores lejanos (colas) pesan muchísimo más.
- -3 : Se resta 3 para que una distribución normal perfecta nos dé **0**.
- **Qué hace**: Mide cómo de "puntiaguda" o "aplastada" es la campana de nuestros datos, fijándose en la cantidad de datos que hay en los extremos (las colas).
- **Para qué se usa**: Para saber la probabilidad de encontrarte con sorpresas extremas en el mercado.
- **Cómo se interpreta**:
 - **Curtosis = 3 (Mesocúrtica)**: Distribución normal estándar.
 - **Curtosis > 3 (Leptocúrtica)**: Campana muy afilada. Casi todos los precios están apelotonados en el centro, pero ¡cuidado!, las colas son "gordas", lo que significa que los pocos outliers que hay son muy, muy extremos.
 - **Curtosis < 3 (Platicúrtica)**: Campana aplastada. Los precios están muy repartidos de forma más plana, no hay un consenso claro de "precio estándar".
- **Ejercicio Real**:

Si en un barrio todas las casas de protección oficial se venden entre $145k$ y $155k$, pero hay una sola parcela industrial vendida por 10 millones:

 1. La mayoría de $(x_i - \bar{x})^4$ serán pequeños (cerca de 0).
 2. Pero el de la parcela industrial será un número **astronómico**.
 3. Eso hará que la Curtosis sea **mucho mayor que 0**. Es un mercado con "colas pesadas".



MÓDULO 2: DISTRIBUCIONES (EL ARTE DE PREDECIR)

En estadística, no usamos una única regla para todo. Dependiendo de lo que queramos medir (precios, número de clientes, tiempos de espera), usamos un "molde" o **Distribución** diferente.

I. Las 3 Funciones Maestras

Antes de ver los "moldes", necesitamos las herramientas para sacar información de ellos.

1. PDF / PMF (Función de Densidad o Masa)

- **Fórmula (General):** $f(x) = P(X = x)$
- **Leyenda:**
 - $f(x)$: La "altura" o probabilidad en el punto exacto x .
 - $P(X = x)$: Probabilidad de que la variable sea exactamente igual al valor elegido.
- **Qué hace:** Te da la probabilidad de un resultado puntual.
 - **PMF (Masa):** Se usa para cosas que se cuentan (1, 2, 3 casas).
 - **PDF (Densidad):** Se usa para cosas continuas (precios, m^2). Como hay infinitos decimales, mide la "concentración" de probabilidad en un punto.
- **Para qué se usa:** Para saber cuál es el valor más frecuente o "típico" (el pico de la campana).
- **Interpretación:** "La probabilidad de que hoy venda exactamente **una** casa es del 20%".
- **Ejemplo Real:** Tienes un dado de 6 caras (distribución uniforme discreta). La PMF para el número 4 es $1/6 = 0.166$. Hay un **16.6%** de probabilidad de sacar un 4.

2. CDF (Función de Distribución Acumulada)

- **Fórmula:** $F(x) = P(X \leq x) = \int_{-\infty}^x f(t)dt$
- **Leyenda:**
 - $F(x)$: Probabilidad acumulada hasta el valor x .
 - $P(X \leq x)$: Probabilidad de que el resultado sea **menor o igual** a x .
 - $\int$: Símbolo de integral (indica que sumamos toda el área bajo la curva desde el inicio hasta x).
- **Qué hace:** Va sumando todas las probabilidades desde la izquierda hasta llegar al punto que tú digas.
- **Para qué se usa:** Para calcular rangos y probabilidades de "hasta aquí".
- **Interpretación:** "El **80%** de las casas del barrio cuestan **300.000€ o menos**".
- **Ejemplo Real:** Si lanzas un dado, ¿cuál es la probabilidad de sacar un 3 o menos? Sumas la probabilidad de 1, 2 y 3. $1/6 + 1/6 + 1/6 = 0.50$. La CDF para el valor 3 es **50%**.

3. PPF (Percent Point Function / Inversa de la CDF)

- **Fórmula:** $x = F^{-1}(p)$
- **Leyenda:**
 - F^{-1} : Función inversa de la CDF.
 - p: Una probabilidad o porcentaje (ej. 0.90).
 - x: El valor del dato (ej. euros) que corresponde a esa probabilidad.
- **Qué hace:** Es la inversa de la CDF. Tú le das un porcentaje (ej. el 90%) y ella te dice qué valor (ej. precio) marca ese límite.
- **Para qué se usa:** Para establecer precios de corte o metas.
- **Interpretación:** "Si quiero que mi casa sea más barata que el **90%** del mercado, ¿qué precio máximo debo poner?".
- **Ejemplo Real:** En un examen, si el percentil 90 es una nota de 8.5, la PPF(0.90) nos devuelve ese **8.5**.

II. Las Distribuciones (Los Moldes)

1. Distribución Uniforme

Todos los valores dentro de un rango tienen exactamente la misma probabilidad.



$$f(x) = \frac{1}{b-a}$$

- **Fórmula (PDF):**
- **Leyenda:**
 - a: Valor mínimo posible.
 - b: Valor máximo posible.
- **Qué hace:** Reparte la probabilidad como una alfombra plana. No hay picos.
- **Para qué se usa:** Cuando no tienes ni idea de qué valor es mejor y assumes que todos son iguales (ej. la posición exacta de una avería en una tubería de 100 metros).
- **Interpretación:** "Cualquier precio entre 200k y 300k es igualmente probable".
- **Ejercicio Real:** Un ayuntamiento sortea una parcela. Las ofertas deben estar entre 1M€ (a) y 1.2M€ (b).
 - **Cálculo:** Probabilidad de que alguien puje exactamente 1.1M€ (PDF) es

$$\frac{1}{1.2-1} = \frac{1}{0.2} = 5$$

(es una densidad).

- **Cálculo (CDF):** ¿Probabilidad de que la puja sea de 1.05M€ o menos?
- $F(1.05) = \frac{1.05-1}{1.2-1} = \frac{0.05}{0.20} = 0.25$ (25%).




o

2. Distribución Normal (La Campana de Gauss)

La más importante. Los datos se agrupan de forma simétrica alrededor de la media.

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}$$


- **Fórmula (PDF):**
- **Leyenda:**
 - μ (Mu): Media de la población (el centro de la campana).
 - σ (Sigma): Desviación típica (qué tan ancha es la campana).
 - e : Constante de Euler (approx 2.718).
 - π : Constante Pi (approx 3.1415).
- **Qué hace:** Modela fenómenos naturales y sociales donde la mayoría está en el centro y los extremos son raros.
- **Para qué se usa:** Tasaciones, metros cuadrados, errores de predicción.
- **Interpretación:** "El 68% de las casas miden entre 80 y 120 m²".
- **Ejercicio Real:** En un barrio de casas adosadas, el tamaño medio es 120m² ($\mu=120$) con una desviación de 10m² ($\sigma=10$).
 - **Pregunta:** ¿Qué probabilidad hay de encontrar una casa de **más de 140m²**?
 - **Cálculo:** 140m² es $\mu + 2\sigma$ (120 + 2 * 10). Por la regla 68-95-99.7, sabemos que por encima de 2 desviaciones solo queda el **2.5%** de los datos.



3. Distribución Binomial (Éxitos en \$n\$ intentos)

Se usa cuando algo solo tiene dos resultados: Éxito o Fracaso (Venta o No Venta).


- **Fórmula (PMF):** $P(x) = \binom{n}{x} p^x (1-p)^{n-x}$
- **Leyenda:**
 - n : Número total de intentos (ej. visitas comerciales).
 - x : Número de éxitos que buscamos.
 - p : Probabilidad de éxito de UN solo intento.
 - $\binom{n}{x}$: Combinatoria (cuántas formas hay de organizar esos éxitos).
- **Qué hace:** Calcula la probabilidad de lograr un número exacto de ventas tras hacer muchas visitas.
- **Para qué se usa:** Previsión de cierres y objetivos de ventas.
- **Interpretación:** "Si enseño la casa a 10 personas, tengo un 20% de probabilidad de vender 2".
- **Ejercicio Real:** Tu tasa de cierre es del 10% ($p=0.10$). Mañana tienes 5 visitas ($n=5$).
 - **Pregunta:** ¿Probabilidad de cerrar **exactamente 1 venta** ($x=1$)?
 - **Cálculo:** $P(1) = 5 \cdot (0.1)^1 \cdot (0.9)^4 = 5 \cdot 0.1 \cdot 0.656 = \mathbf{0.328}$ (32.8%).



4. Distribución de Poisson (Eventos por tiempo/espacio)

Mide cuántas veces ocurre algo en un intervalo (una hora, un día, un km²).

- **Fórmula (PMF):** $P(x) = \frac{e^{-\lambda} \lambda^x}{x!}$
- **Leyenda:**
 - λ (Lambda): El promedio de eventos que suelen ocurrir en ese tiempo.
 - x: El número de eventos que queremos predecir.
 - e: Constante de Euler.
 - x!: Factorial (multiplicar el número por todos los anteriores: $3! = 3 * 2 * 1$).
- **Qué hace:** Modela la llegada de clientes o llamadas.
- **Para qué se usa:** Gestión de colas y personal en la oficina inmobiliaria.
- **Interpretación:** "Suelen entrar 2 personas por hora, ¿qué probabilidad hay de que entren 4?".
- **Ejercicio Real:** En tu oficina entran de media 4 clientes al día ($\lambda = 4$).
 - **Pregunta:** ¿Probabilidad de que mañana sea un día movido y entren 6 clientes?
 - **Cálculo:** $P(6) = \frac{e^{-4} 4^6}{6!} = \frac{0.0183 \cdot 4096}{720} = \mathbf{0.104 \text{ (10.4\%)}$.




5. Distribución Exponencial (Tiempos de espera)

Es la hermana de la Poisson. Si Poisson cuenta cuántos entran, la Exponencial mide el **tiempo entre uno y otro**.

$$f(x) = \lambda e^{-\lambda x}$$


- **Fórmula (PDF):**
- **Leyenda:**
 - λ : La misma tasa de la Poisson (ej. 2 clientes por hora).
 - x: El tiempo de espera que evaluamos.
 - e: euler
- **Qué hace:** Modela procesos donde los eventos son independientes y ocurren de forma continua.
- **Para qué se usa:** Tiempo hasta que se vende una casa o tiempo entre llamadas.
- **Interpretación:** "Hay un 40% de probabilidad de que el próximo cliente entre en menos de 15 minutos".
- **Ejercicio Real:** Recibes 1 llamada cada 2 horas ($\lambda = 0.5$ llamadas/hora).
 - **Pregunta:** ¿Probabilidad de esperar **más de 4 horas** para la siguiente llamada?
 - **Cálculo (CDF invertida):** $P(X > 4) = e^{-0.5 \cdot 4} = e^{-2} = \mathbf{0.135}$ (13.5%).



6. Distribución Log-Normal

Es la distribución "reina" de los precios de las casas. No hay precios negativos y hay una cola infinita hacia la derecha.

- **Fórmula (PDF):**
$$f(x) = \frac{1}{x\sigma\sqrt{2\pi}} e^{-\frac{(\ln x - \mu)^2}{2\sigma^2}}$$
- **Leyenda:**
 - $\ln x$: Logaritmo natural del precio.
 - μ : Media
 - σ : desviación del logaritmo de los precios.
 - pi: 3.14
 - e: euler, 2.718
- **Qué hace:** Si le aplicas un logaritmo a los precios de las casas, se convierten en una Distribución Normal. Refleja que es más fácil que una casa suba de 200k a 400k (doblar valor) que baje de 200k a 0k.
- **Para qué se usa:** Valoración de activos financieros y Real Estate.
- **Interpretación:** "La mayoría de las casas son de precio medio, pero existe una 'cola de lujo' con mansiones de 20 millones que ocurre con baja frecuencia".



MÓDULO 3: ESTADÍSTICA AVANZADA (RELACIONES Y CORRELACIONES)

Para los ejercicios, usaremos estos datos de **5 casas**:

- **Superficie (x):** 60, 80, 100, 120, 140 (m²)
- **Precio (y):** 150k, 200k, 250k, 300k, 350k (€)

1. Covarianza Muestral

- **Fórmula:**


$$Cov(X, Y) = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{n - 1}$$

- **Leyenda:**


- $Cov(X, Y)$: Covarianza entre la variable X e Y .
- x_i, y_i : Cada valor individual de superficie y precio.
- $\bar{x}, \bar{y}$: Media de la superficie y media del precio.
- $n - 1$: Número de datos menos uno.
- **Qué hace:** Mide si dos variables se mueven en la misma dirección. Si cuando x sube, y también sube, la covarianza será positiva.
- **Para qué se usa:** Es el motor matemático para calcular la correlación. Por sí sola no es muy útil porque depende de las unidades (m² y €).
- **Cómo se interpreta:**
 - **Positiva:** Se mueven juntas (suben las dos).
 - **Negativa:** Se mueven al revés (una sube, otra baja).
 - **Cero:** No hay relación lineal evidente.
- **Ejercicio Real:**
 - $\bar{x} = 100, \bar{y} = 250k$.
 - Para la casa 1 (60, 150k): $(60 - 100) \cdot (150 - 250) = (-40) \cdot (-100) = +4000$.

- Al sumar todos y dividir entre $n-1$, nos da un número **positivo**. Confirmado: a más metros, más precio.


Correlation Coefficient



Positive Correlation



Negative Correlation



No Correlation

2. Coeficiente de Correlación de Pearson (r)

- **Fórmula:**

$$r = \frac{Cov(X, Y)}{s_x \cdot s_y}$$

- **Leyenda:**
 - r: Coeficiente de Pearson.
 - Cov(X,Y): Covarianza calculada antes.
 - sx, sy: Desviación típica de X y de Y.
 - **Qué hace:** "Normaliza" la covarianza para que el resultado siempre esté entre **-1 y 1**, eliminando las unidades (m² y €).
 - **Para qué se usa:** Para medir la **fuerza** de la relación lineal.
 - **Cómo se interpreta:**
 - **1:** Relación lineal positiva perfecta (suben en línea recta).
 - **-1:** Relación lineal negativa perfecta (ej. a más antigüedad, menos precio).
 - **0:** No hay ninguna relación lineal.
 - **Ejercicio Real:**
 - Si calculamos r para nuestros datos de superficie y precio, nos daría **$r = 1$** . Es una relación perfecta: por cada m² extra, el precio sube exactamente la misma proporción.
-

3. Coeficiente de Correlación de Spearman (ρ)

- **Fórmula:**

$$\rho = 1 - \frac{6 \sum d_i^2}{n(n^2 - 1)}$$

- **Leyenda:**

- d_i : Diferencia entre el **rango** de x y el **rango** de y (ej. si una casa es la 1ª en m² pero la 3ª en precio).
- n: Número de datos.
- **Qué hace:** En lugar de usar los números (60m², 100m²), usa el **orden** (la más pequeña, la mediana, la más grande).
- **Para qué se usa:** Cuando la relación no es una línea recta o cuando hay **outliers** (mansiones) que engañarían a Pearson.
- **Cómo se interpreta:** Mide si la relación es "monótona" (siempre sube, aunque no sea en línea recta).
- **Ejercicio Real:** Imagina que el precio sube con la planta del edificio (1º, 2º, 3º). Quizás del 1º al 2º sube 5k, pero del 9º al 10º (ático) sube 100k. Pearson fallaría, pero Spearman vería que el orden se mantiene y daría un valor cercano a **1**.

4. Coeficiente de Determinación (R^2)

- **Fórmula:**


$$R^2 = r^2$$

(En regresión simple es el cuadrado de Pearson)

- **Qué hace:** Convierte la correlación en un **porcentaje**.
- **Para qué se usa:** Para saber cuánto de una variable explica la otra.
- **Cómo se interpreta:** "El tamaño de la casa explica el **80%** del precio. El otro 20% depende de otras cosas (barrio, estado, etc.)".
- **Ejercicio Real:** Si $r = 0.90$ entre m² y precio, $R^2 = 0.81$. El **81%** de la variación del precio se explica solo por los metros cuadrados.

5. El Cuarteto de Anscombe

- **Qué es:** Un conjunto de 4 gráficos que tienen la **misma media, misma desviación y mismo Pearson**, pero que al dibujarlos son totalmente distintos.
- **Para qué se usa:** Para demostrar que **nunca** debes confiar solo en los números; ¡tienes que ver el gráfico!
- **Lección Inmobiliaria:** Puedes tener dos barrios con el mismo precio medio y misma correlación con los m², pero en uno los datos son una línea perfecta y en otro hay una casa loca que rompe todo.



6. Correlaciones Falsas (Espurias)

- **Qué son:** Cuando dos variables tienen un Pearson alto pero **no tienen ninguna relación real**.
- **Causa:** Suele haber una "tercera variable" oculta.

Características:

- Tienen un coeficiente de Pearson (r) alto.
- No hay una conexión causal directa.
- Suelen aparecer por una **tercera variable oculta** o por puro azar.

¿Cómo se comprueba?

1. **Sentido Común/Teoría:** ¿Hay alguna razón lógica para que X cause Y ?
 2. **Prueba de la Variable de Control:** Usas la **Correlación Parcial**. Si al introducir una variable lógica (Z), la correlación original desaparece o baja drásticamente, la primera era espuria.
 3. **Aumento de Muestra:** Si la relación desaparece al añadir más datos, era puro azar.
- **Ejemplo Real:** Las ventas de helados y las ventas de casas suben a la vez en julio (r alto). ¿Significa que comer helado te hace comprar casas? No. La variable oculta es el **Buen Tiempo/Verano**.

7. Correlación Parcial

- **Fórmula:**

$$r_{xy.z} = \frac{r_{xy} - (r_{xz} \cdot r_{yz})}{\sqrt{(1 - r_{xz}^2) \cdot (1 - r_{yz}^2)}}$$

- **Leyenda:**

- $r_{xy.z}$: Correlación entre X e Y eliminando (controlando) el efecto de la variable Z .
 - r_{xy} : Correlación simple entre X e Y .
 - r_{xz} : Correlación entre X y la variable de control Z .
 - r_{yz} : Correlación entre Y y la variable de control Z .
- **Qué hace:** Limpia la relación. Imagina que quieres saber si el **Número de Ventanas** (X) influye en el **Precio** (Y). Pero sabes que las casas más **Grandes** (Z) tienen más ventanas y son más caras. La correlación parcial "congela" el tamaño de la casa para ver si las ventanas, por sí solas, aportan valor.
 - **Para qué se usa:** Para evitar que variables "metomentodo" nos engañen.
 - **Ejercicio Real:**
 - Correlación m² y Precio (r_{xy}) = **0.80**.
 - Correlación m² y Vistas al mar (r_{xz}) = **0.60**.
 - Correlación Precio y Vistas al mar (r_{yz}) = **0.70**.
 - Al aplicar la fórmula, si el resultado baja de **0.80 a 0.20**, significa que los m² no eran tan importantes; lo que de verdad pagaba la gente eran las **Vistas**.

8. El Test T (Prueba de Hipótesis)

- **Fórmula (para correlación):**

$$t = \frac{r\sqrt{n-2}}{\sqrt{1-r^2}}$$

- **Leyenda:**
 - t: Valor del estadístico T.
 - r: Coeficiente de correlación que has calculado.
 - n: Tamaño de la muestra (número de casas).
 - **Qué hace:** Mide la distancia entre tu resultado y el "cero" (la nada), teniendo en cuenta cuántos datos has usado.
 - **Para qué se usa:** Para saber si el resultado que has obtenido es "sólido" o si ha podido ocurrir por pura suerte al elegir las casas de la muestra.
 - **Interpretación:** Cuanto más alto sea el valor de t (en valor absoluto), más pruebas tienes de que la correlación es real.
-

9. El P-Valor (Valor de Probabilidad)

Este es el número más famoso y temido de la estadística.

- **Qué es:** Es la probabilidad de que tu resultado sea fruto del azar. Es decir, la probabilidad de que en realidad **no haya relación**, pero tus datos parezcan decir que sí por pura coincidencia.
- **Cómo se calcula:** Se obtiene a partir del valor de t y los grados de libertad (n-2) usando una tabla de distribución o software (Python/Excel).
- **Cómo se interpreta (La regla de oro):**
 - **P < 0.05:** ¡Eureka! Es **Estadísticamente Significativo**. Hay menos de un 5% de probabilidad de que sea azar. Confiamos en el resultado.
 - **P >= 0.05:** No es significativo. No podemos descartar que el resultado sea una coincidencia.
- **Resultados habituales:**
 - **P = 0.01:** Muy fuerte. Solo 1% de probabilidad de error.
 - **P = 0.50:** Es lanzar una moneda al aire. El resultado no vale nada.

MÓDULO 4: REGRESIONES Y SERIES TEMPORALES

I. Regresión Lineal Simple

Es la herramienta para trazar la "línea de mejor ajuste" entre dos variables.

- **Fórmula:**

$$\hat{Y} = \beta_0 + \beta_1 X + \epsilon$$

Leyenda:

- $\hat{Y}$ (Y con gorrito): El valor que queremos **predecir** (ej: Precio).
- X : La variable que usamos para predecir (ej: Metros cuadrados).
- β_0 (Beta sub-cero o Intercepto): El valor de Y cuando X es cero. Es el punto de partida de la línea.
- β_1 (Beta sub-uno o Pendiente): Cuánto cambia Y por cada unidad que sube X .
- ϵ (Epsilon): El **error** o residuo. La distancia entre la realidad y nuestra línea.
- **Qué hace:** Intenta resumir la relación entre dos variables en una línea recta matemática.
- **Para qué se usa:** Para estimar el valor de una vivienda basándonos en una de sus características.
- **Cómo se interpreta:** Si β_1 es 2.000, significa que "por cada metro cuadrado extra, el precio de la casa sube 2.000 €".
- **Ejercicio Real:**

Imagina que tras analizar un barrio, tu modelo dice: $\text{\$Precio} = 30.000 + 1.500 \cdot \text{m}^2$.

 - Si tienes una casa de **100 m²**:
 - Cálculo: $30.000 + (1.500 \cdot 100) = 30.000 + 150.000 = 180.000 \text{ €}$.

II. Mínimos Cuadrados Ordinarios (OLS)

1. La Función Objetivo (Lo que buscamos minimizar)

- **Fórmula:**

$$\min \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \min \sum_{i=1}^n (y_i - (\beta_0 + \beta_1 x_i))^2$$

- **Leyenda:**

- $\min \sum$: Indica que buscamos el valor mínimo de la suma total.
- $(y_i - \hat{y}_i)$: Es el **Residuo** (la distancia vertical entre la realidad y la línea).
- 2 : Elevamos al cuadrado para que los errores negativos no se cancelen con los positivos y para penalizar mucho más los fallos grandes.
- **Qué hace:** Es el "cerebro" que decide dónde poner la línea roja.
- **Explicación:** OLS busca la línea que minimice la suma de los **errores al cuadrado** (ϵ^2). Eleva los fallos al cuadrado para que los errores grandes "duelan" más y el modelo intente evitarlos a toda costa.
- **Para qué se usa:** Es el método estándar para calcular β_0 y β_1 de forma que la línea pase lo más cerca posible de todos los puntos.

III. Regresión Lineal Múltiple

La realidad es compleja. Una casa no vale solo por sus metros; también cuenta el número de baños, la planta o la antigüedad.

- **Fórmula:**

$$\hat{Y} = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p + \epsilon$$

- **Leyenda:**

- X_1, X_2 : Diferentes variables (m², número de habitaciones, etc.).

- β_1, β_2 : El impacto específico de cada variable.

- **Qué hace:** Evalúa el peso de varios factores a la vez.

- **Interpretación:** "A igualdad de metros cuadrados (**Ceteris Paribus**), tener un baño extra sube el precio en 10.000 €".

- **Ejercicio Real:**

Modelo: Precio = 20.000 + (1.200 * m²) + (5.000* Hab).

- Casa de **80 m²** con **3 habitaciones**:

- Cálculo: 20.000 + (1.200 * 80) + (5.000* 3) = 20.000 + 96.000 + 15.000 = 131.000 €.

IV. Evaluación del Error y Métricas

¿Cómo sabemos si nuestra fórmula es buena o es una basura? Comparamos lo que predijo la línea ($\hat{y}$) con el precio real que se pagó (y).

1. MAE (Error Medio Absoluto)

- **Fórmula:**

$$MAE = \frac{1}{n} \sum |y_i - \hat{y}_i|$$

Leyenda:

- MAE : El error promedio en las mismas unidades que tus datos (euros).
- n : Número de casas que estamos evaluando en el set de **Test**.
- y_i : El precio **Real** al que se vendió la casa i .
- $\hat{y}_i$: El precio que tu modelo **Predijo** para esa misma casa.
- $|\dots|$: Valor absoluto (convierte los errores negativos en positivos).
- **Qué hace:** Suma todos los fallos (sin importar si te pasaste o te quedaste corto) y hace la media.
- **Para qué se usa:** Es la métrica para hablar con el jefe o el cliente. Es muy intuitiva.
- **Cómo se interpreta:** "En promedio, mi tasación falla por +-X euros".
- **Ejercicio Real:** * Casa A: Real 200k, Predicho 190k (Error = 10k).

Casa B: Real 150k, Predicho 165k (Error = -15k-> 15k).

- **MAE:** $(10.000 + 15.000) / 2 = 12.500$ €. Fallas por 12.500€ de media.

2. MSE y RMSE (Raíz del Error Cuadrático Medio)

- **Fórmula (RMSE):**

$$MSE = \frac{1}{n} \sum (y_i - \hat{y}_i)^2 \rightarrow RMSE = \sqrt{MSE}$$

Leyenda:

- 2 : Elevamos el error al cuadrado. Esto hace que los errores grandes "pesen" muchísimo más que los pequeños.
- $\sqrt{}$: Aplicamos la raíz para volver a tener el resultado en euros.

Qué hace: Penaliza desproporcionadamente los fallos catastróficos.

Cómo se interpreta: Si el RMSE es mucho mayor que el MAE, significa que tienes "outliers" en tu error (casas donde el modelo ha fallado por muchísimo).

Ejercicio Real: Usando los datos anteriores:

- Casa A: $10.000^2 = 100.000.000$.
- Casa B: $15.000^2 = 225.000.000$.
- **RMSE:** $\sqrt{(100M + 225M)/2} = \sqrt{162.5M} \approx 12.747€$.

3. Coeficiente de Determinación (R^2)

1. La Fórmula Matemática

$$R^2 = 1 - \frac{SS_{\text{res}}}{SS_{\text{tot}}} = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$$

2. Leyenda de la Fórmula

- R^2 : Coeficiente de determinación.
- SS_{res} (**Suma de Cuadrados de los Residuos**): Es el error total de **tu modelo**. Es la suma de las distancias al cuadrado entre los puntos reales (y_i) y tu línea de predicción ($\hat{y}_i$).
- SS_{tot} (**Suma de Cuadrados Totales**): Es la variabilidad total de los datos. Compara los puntos reales (y_i) contra la media simple ($\bar{y}$).
- y_i : Precio real de venta de la casa.
- $\hat{y}_i$: Precio que predijo tu modelo.
- $\bar{y}$: El precio medio de todas las casas del barrio.

3. ¿Qué hace y para qué se usa?

- **Qué hace**: Compara tu modelo contra un modelo "vago" o base que simplemente dijera que todas las casas valen lo mismo (la media).
- **Para qué se usa**: Para contextualizar la bondad del ajuste y comparar modelos entre sí, independientemente de si los precios están en euros o en millones.

4. ¿Cómo se lee el resultado?

El resultado suele ser un número entre **0 y 1** (aunque puede ser negativo si el modelo es desastroso).

- **$R^2 = 1.0$** : Modelo perfecto. Tu línea pasa exactamente por todos los puntos.
- **$R^2 = 0.0$** : Tu modelo no aporta nada. Es igual de útil que decir simplemente el precio medio para todo.
- **$R^2 = 0.85$** : El 85% de los cambios en el precio de las casas se explican por las variables que has usado (metros, habitaciones, etc.). El otro 15% es ruido o factores que no conoces.

5. Ejercicio Real Resuelto (Paso a Paso)

Imagina que tenemos **3 casas** vendidas por: 100k, 200k y 300k.

- La **media** ($\bar{y}$) es 200k.
- Tu modelo predice para estas casas: 110k, 190k y 310k.

Paso 1: Calcular la Variabilidad Total (SStot)

Comparamos la realidad contra la media simple:

1. $(100 - 200)^2 = 10.000$
 2. $(200 - 200)^2 = 0$
 3. $(300 - 200)^2 = 10.000$
- **SStot = 20.000**

Paso 2: Calcular el Error de tu Modelo (SSres)

Comparamos la realidad contra tu predicción:

1. $(100 - 110)^2 = 100$
 2. $(200 - 190)^2 = 100$
 3. $(300 - 310)^2 = 100$
- **SSres = 300**

Paso 3: Aplicar la fórmula del R²

$$R^2 = 1 - \frac{300}{20.000} = 1 - 0.015 = \mathbf{0.985}$$

Interpretación del resultado:

Tu modelo tiene un **R² de 0.985**. Esto significa que tu fórmula explica el **98.5%** de la variación de los precios en este ejemplo. ¡Es un modelo excelente!.

V. Series Temporales (Dominando el Tiempo)

Aquí el dato no es una casa suelta, sino la **Venta Mensual** de tu inmobiliaria a lo largo de los años.

1. El Modelo Aditivo

Fórmula:

$$R^2 = 1 - \frac{SS_{\text{res}}}{SS_{\text{tot}}}$$

Leyenda:

- SS_{res} : Suma de los errores de tu modelo al cuadrado.
- SS_{tot} : Variabilidad total de los precios respecto a su media.

O también:

- **Fórmula:**

$$Y_t = T_t + S_t + C_t + \epsilon_t$$

- **Leyenda:**
 - T_t (**Tendencia**): La dirección a largo plazo (¿el mercado inmobiliario sube año tras año?).
 - S_t (**Estacionalidad**): Patrones que se repiten (¿vendemos más en primavera que en navidad?).
 - C_t (**Ciclo**): Subidas y bajadas por la economía (crisis, auges).
 - ϵ_t (**Ruido**): Lo impredecible.
- **Qué hace:** Compara tu modelo contra un modelo "tonto" que solo dijera siempre el precio medio.
- **Cómo se interpreta:**
 - **0.0:** Tu modelo es inútil.
 - **1.0:** Tu modelo es perfecto (predice el 100% de la realidad).

- **0.80:** El 80% de la variación de los precios se explica por tu modelo.

Ejemplo: Si $R^2 = 0.60$, significa que tus variables (m^2 , habitaciones...) explican el **60%** del precio. El otro 40% es azar o cosas que no mediste (vistas, vecinos...).

2. Diferenciación

- **Fórmula:**

$$\Delta Y_t = Y_t - Y_{t-1}$$

- **Leyenda:**

- Y'_t : La serie "diferenciada".

Qué hace: Convierte una serie con tendencia (que sube o baja) en una serie **Estacionaria** (plana).

Por qué se usa: Muchos modelos de predicción fallan si la serie no es estacionaria (si su media y varianza cambian con el tiempo).

Interpretación: Ya no miras el precio total, sino "**cuánto ha cambiado**" respecto al mes pasado.

Ejercicio Real: Precios: Ene (200k), Feb (210k), Mar (225k).

- **Diff 1:** Feb-Ene = +10k.
- **Diff 2:** Mar-Feb = +15k.
- La serie original subía (no estacionaria). La diferenciada nos muestra el ritmo de crecimiento mensual.

Medias Móviles (Moving Average)

- **Fórmula:**

$$MA_t(n) = \frac{y_t + y_{t-1} + \dots + y_{t-n+1}}{n}$$

- **Leyenda:**

- n : El tamaño de la ventana (ej: 7 días o 12 meses).
- y_{t-1} : El valor del periodo anterior.
- **Qué hace:** Suaviza los saltos bruscos para que la **Tendencia** sea visible.
- **Ejercicio Real:** Ventas de 3 meses: Ene (10), Feb (15), Mar (11).
 - **Media Móvil (n=3):** $(10 + 15 + 11) / 3 = \mathbf{12}$.
 - Aunque febrero fue un mes "loco" de 15 ventas, la media móvil nos dice que el nivel real de ventas es **12**.