



SMOTE (Synthetic Minority Oversampling Technique)

1. Busca sus **K vecinos más cercanos** (también de la clase minoritaria)
2. Elige uno de esos vecinos al azar
3. Genera un punto nuevo **en algún lugar del segmento** que une los dos puntos

Ejemplo

1. Toma un "1" existente: [edad=25, ingresos=30k, saldo=500]
2. Busca sus K vecinos más cercanos entre los otros "1"s
3. Elige uno al azar: [edad=35, ingresos=50k, saldo=800]
4. Genera un número aleatorio λ entre 0 y 1: $\lambda = 0.3$
5. Nuevo punto = original + $\lambda \times (\text{vecino} - \text{original})$
 $\text{edad} = 25 + 0.3 \times (35 - 25) = 28$
 $\text{ingresos} = 30 + 0.3 \times (50 - 30) = 36\text{k}$
 $\text{saldo} = 500 + 0.3 \times (800 - 500) = 590 \rightarrow \text{Nuevo "1": [edad=28, ingresos=36k, saldo=590]}$

Código

```
from imblearn.over_sampling import SMOTE

smote = SMOTE(
    sampling_strategy='not majority', # sobremuestrea todas
    menos la mayoritaria
    k_neighbors=5, # vecinos para generar sintéticos
    random_state=42 )

X_res, y_res = smote.fit_resample(X_train, y_train)
```

- El resultado es un punto que no es ninguno de los originales, pero está en la misma "zona" del espacio de features.
- Conviene utilizar datos escalados
- Siempre aplicar SMOTE **solo sobre el train set**, nunca sobre el test. Si lo aplicas antes del split estás contaminando el test con puntos sintéticos generados a partir de datos reales del train.