



Sistemas de recomendación



Sistemas de recomendación



Los motores de recomendación son un tipo de algoritmos de aprendizaje automático que generalmente se ocupan de la calificación de productos.




Un sistema de recomendación puede emplear algoritmos supervisados y no supervisados.

Por ejemplo, es supervisado cuando trata de predecir las valoraciones (ratings) que un usuario podría dar a un elemento específico. Y no es supervisado cuando se basa en similitud entre items o usuarios.




Son muy utilizados por varias empresas como **Google, Instagram, Spotify, Amazon, Reddit, Netflix**, entre otras, con el objetivo de aumentar la interacción de los usuarios con la plataforma.


Por ejemplo, **Spotify** recomendaría canciones similares a las que has escuchado repetidamente o que te han gustado, para que sigas utilizando su plataforma para escuchar música.





Un sistema de recomendación es una subclase de sistemas de filtrado de información que busca predecir la "calificación" o "preferencia" que un usuario otorgaría a un elemento.





1

Popular Based

Esta es la recomendación más intuitiva que podemos encontrar en cualquier lugar. Ejemplos de esto son las películas mejor valoradas en IMDB, el "Top 10 en tu país hoy" en Netflix, etc. Estas recomendaciones suelen aparecer cuando eres un nuevo usuario y el proveedor no tiene suficiente información sobre ti. Por lo tanto, es una apuesta segura sugerirte lo que a otros les gusta. Limitación: Todos los usuarios reciben el mismo conjunto de recomendaciones. No es personalizado.

2

Content Based

Incorpora las características de cada elemento (ej. género, autor, palabra clave, ...) para hacer recomendaciones más relevantes según los gustos del usuario. Por ejemplo, en Netflix puedes ver una lista de contenidos recomendados porque te ha gustado una película específica. Limitación: La recomendación se basará únicamente en lo que los usuarios han visto, les ha gustado o con lo que han interactuado antes. Todos los usuarios que disfruten del elemento X recibirán el mismo conjunto de recomendaciones.



Sistemas de recomendación: filtro colaborativo



El filtrado colaborativo recomienda un conjunto de elementos basado en lo que se conoce como la matriz de interacción usuario-elemento.

Podemos hablar de rating explícito, cuando preguntamos al usuario directamente que califique el elemento o implícito, cuando inferimos esta calificación o rating (ejemplo: minutos viendo la película).



User-Item Interaction Matrix

User / Item	Item 1	Item ...	Item m
User 1	3		1
User ...	2		
User n		5	

User-based

La recomendación se basa en un grupo de usuarios similares que se derivan de la matriz de interacción usuario-elemento. La recomendación cambiará en función del grupo de usuarios similares y este grupo a su vez cambiará a medida que el usuario vaya añadiendo nuevas calificaciones.

Limitación

Se basa en la información de la matriz, por lo que si el usuario es nuevo y no hay calificaciones previas entonces no genera recomendaciones → cold-start.




Item-based

Buscamos grupos de elementos similares al que el usuario #1 acaba de indicar que le gusta y se lo recomendaremos. Este método es parecido a la recomendación basada en popularidad o contenido. La diferencia radica en cómo se determina el conjunto de elementos similares. Aquí usamos la matriz de interacción usuario-elemento en lugar de las valoraciones o géneros.

Limitación

Se requiere información previa. Se puede solucionar proporcionando primero la recomendación basada en contenido para el nuevo elemento hasta que haya suficiente información disponible.

Collaborative Filtering vs Content Based





Memory based

Calcula la similitud entre usuarios o elementos aplicando las métricas de similaridad directamente sobre la matriz user-item. Métricas de similaridad: Correlación de Pearson, Similaridad del Coseno.

Limitación: el desequilibrio entre la cantidad de usuarios y elementos hace que la matriz de interacción usuario-elemento sea muy dispersa, lo que provoca una mala generalización de los resultados predichos. También cada vez que entran elementos o usuarios nuevos hay que recalcular todo. Para simplificar este proceso se emplean técnicas de descomposición de matrices: SVD → model based.

Model based

La diferencia clave entre los métodos model-based y los métodos memory-based es que model-based implica la construcción de un modelo a partir del conjunto de datos de valoraciones; se extraen los datos de la matriz de interacción usuario-elemento y se utilizan como modelo para hacer recomendaciones.

Esto resuelve el problema de escalabilidad y facilita la implementación en aplicaciones reales.

Técnicas más comunes: TruncatedSVD, Funk Matrix Factorization, Generalized Matrix Factorization (GMF); Neural Collaborative Filtering.

Python Libraries: Surprise, LightFM, SKlearn, TensorFlow, implicit

<https://pypi.org/project/scikit-surprise/>



Algoritmos disponibles en Surprise

Librería Python para filtrado colaborativo con ratings explícitos. API idéntica a scikit-learn.

Familia	Algoritmo	Descripción	Cuándo usarlo
Factorización matricial	SVD	Singular Value Decomposition. Ganador del Netflix Prize	Caso general. Mejor equilibrio precisión/velocidad
	SVD++	Extiende SVD con ratings implícitos. Más preciso, más lento	Cuando el tiempo de entrenamiento no es crítico
	NMF	Non-negative Matrix Factorization. Factores positivos	Cuando la interpretabilidad importa
	PMF	Versión probabilística de SVD	Investigación o modelos bayesianos
Vecinos (KNN)	KNNBasic	KNN sin corrección de sesgo	Baseline rápido
	KNNWithMeans	Descuenta la media del usuario antes de comparar	Uso general. Mejor que KNNBasic
	KNNWithZScore	Normaliza además por desviación estándar	Usuarios con escalas de rating muy distintas
	KNNBaseline	Corrección de sesgos usuario+ítem. El más preciso de los KNN	Cuando se prioriza precisión sobre velocidad
Baseline	BaselineOnly	Solo sesgos global + usuario + ítem. Sin factores ni vecinos	Referencia mínima competitiva, muy rápido
	NormalPredictor	Predicción aleatoria según distribución del dataset	Solo como lower bound de comparación



Métricas de evaluación en sistemas de recomendación

Ninguna métrica sola cuenta la historia completa — se usan siempre en conjunto.

Tipo	Métrica	Interpretación	Cuándo usarla
Error	RMSE	Me equivoco en X★ penalizando errores grandes. Sensible a outliers	Comparar modelos globalmente
	MAE	Me equivoco de media en X★. Más interpretable que RMSE	Comunicar resultados a negocio
Ranking	Precision@K	Del top-K recomendado, % con rating real $\geq$ 4★	Listas cortas — apps móvil, widgets
	Recall@K	De todos los ítems buenos del usuario, % en el top-K	Descubrimiento de contenido
	NDCG@K	Como Precision pero ponderado por posición. Pos.1 vale más que Pos.5	Cuando el orden de la lista importa
Diversidad	Coverage	% del catálogo que aparece en alguna recomendación	Detectar popularity bias

Trade-off Precision vs Recall

	K pequeño (lista corta)	K grande (lista larga)
Precision	Alta — lista precisa, poco ruido	Baja — entra más ruido
Recall	Bajo — me dejo relevantes fuera	Alto — cubro más gustos del usuario

*NDCG desempata cuando Precision y Recall son similares:
mide si los aciertos aparecen al principio de la lista.*