




Módulo de IA Generativa

Bloque II

Ingeniería de prompts



Victor Prior

Senior AI & Big Data Strategy Consultant
Telefónica Tech

Sobre mí

Apasionado por la inteligencia artificial y los datos, me dedico a ayudar a empresas a convertirse en organizaciones guiadas por decisiones inteligentes. Actualmente, trabajando en Telefónica, mi core de funcionalidades se basa en el liderazgo de proyectos con equipos multidisciplinarios, uniendo lo técnico con lo estratégico, y siempre buscando el impacto real en el negocio.

Me gusta lo complejo, pero disfruto haciéndolo simple y útil. Siempre con mentalidad ágil, curiosidad constante y ganas de transformar.



En que consiste y como está estructurado el módulo

En este módulo aprenderás a dominar los fundamentos, herramientas y aplicaciones prácticas de la IA Generativa. Desde cómo funcionan los grandes modelos de lenguaje (LLMs) hasta cómo integrarlos en productos reales con responsabilidad y criterio.

- 1

Introducción a LLMs e integración con APIs
Visión general de los modelos de lenguaje (LLMs), cómo funcionan a nivel conceptual y cómo integrarlos en aplicaciones reales mediante APIs para construir soluciones basadas en IA.
- 2

Ingeniería de Prompts
Aprenderás a diseñar prompts efectivos para obtener resultados precisos y útiles, aplicando técnicas avanzadas como prompting estructurado, few-shot y control de comportamiento del modelo.
- 3

RAG – Retrieval Augmented Generation
Exploración del patrón RAG para conectar LLMs con fuentes de datos externas, mejorando la precisión y contextualización de las respuestas mediante recuperación de información.
- 4

Pipelines ML + GenAI
Construcción de pipelines que combinan modelos de Machine Learning tradicionales con IA generativa, integrando procesamiento de datos, inferencia y generación de contenido.
- 5

Tutoría y ejercicios prácticos
Sesión enfocada en resolver dudas y aplicar lo aprendido mediante ejercicios guiados, reforzando conceptos clave con casos reales.
- 6

Agentes de IA: arquitectura, herramientas y memoria
Introducción a los agentes autónomos: cómo se estructuran, qué componentes los forman (herramientas, memoria, planificación) y cómo diseñarlos.
- 7

Frameworks de Agentes: LangChain y LangGraph
Uso práctico de frameworks populares para construir agentes, orquestar flujos y gestionar estados complejos en aplicaciones con IA.
- 8

Agentes en AWS Bedrock
Despliegue y gestión de agentes utilizando AWS Bedrock, integrando modelos fundacionales con servicios cloud para soluciones escalables.
- 9

Orquestación y despliegue de agentes + proyecto
Diseño completo de sistemas con agentes: orquestación, despliegue en producción y desarrollo de un proyecto final integrando todos los conceptos del curso.
- 10

Tutoría y resolución de dudas del proyecto
Espacio para resolver dudas, revisar avances y recibir orientación personalizada para mejorar el proyecto.



Bienvenidos al módulo en IA Generativa

1

¿Qué es la IA Generativa?

- Es una rama de la IA capaz de crear contenido original: texto, código, imágenes, música y más.
- Utiliza modelos avanzados como Transformers y LLMs (Large Language Models).
- A diferencia de la IA clásica, no solo analiza datos... genera resultados creativos.

2

¿Por qué aprender esto ahora?

- Los LLMs ya están transformando el trabajo en múltiples industrias.
- Su adopción es rápida, pero su comprensión sigue siendo superficial para muchos.
- Aquí aprenderás desde dentro cómo funcionan y cómo aplicarlos con criterio.

3

Enfoque del curso: Aprender Haciendo

- En Evolve, cada clase tiene un enfoque 100% práctico. Nada de relleno. Aprenderás lo justo y necesario para aplicar IA generativa en el mundo real desde hoy.



Fundamentos de IA Generativa y LLMs

La IA Generativa marca un cambio de paradigma: ya no solo analiza datos, ahora los crea. En esta sección sentamos las bases del módulo, explorando qué es la IA Generativa, por qué es tan disruptiva y cómo se diferencia de la IA tradicional.

Contexto y arranque visual

La IA Generativa marca un cambio de paradigma: ya no solo analiza datos, ahora los crea. En esta sección sentamos las bases del módulo, explorando qué es la IA Generativa, por qué es tan disruptiva y cómo se diferencia de la IA tradicional.

La evolución de los modelos

Antes de comprender lo que puede hacer un LLM, es clave saber cómo está construido. Aquí desglosamos su estructura básica: embeddings, capas de atención, normalización, capas lineales y más. Una mirada desde adentro al “cerebro” del modelo.

Arquitectura del Transformer

El Transformer es la arquitectura base detrás de todos los LLMs modernos. En esta sección explicamos cómo funciona su diseño: atención multi-cabeza, capas encoder/decoder, posiciones relativas y cómo reemplazó a las RNNs y CNNs.

Mecanismo de atención

“Atención” no es solo una palabra de moda: es el motor que permite a los modelos enfocarse en partes relevantes del contexto. Aquí entenderás cómo y por qué funciona, y verás visualmente cómo un modelo “decide” a qué poner atención.

Capacidades y usos de los LLMs

Los LLMs son modelos versátiles: pueden redactar, traducir, razonar, generar código y más. Exploramos las tareas clave que pueden realizar, sus límites actuales y qué los hace tan útiles en el mundo real.

Modelos más importantes

Existen múltiples modelos de lenguaje, cada uno con sus ventajas, limitaciones y enfoque. En este bloque conocerás los principales: GPT, Claude, Gemini, LLaMA, Mistral, y aprenderás cuándo conviene usar uno u otro.



Contexto y arranque visual




¿Cómo hemos llegado hasta la IA Generativa?

La IA generativa no apareció de la nada. Es el resultado de décadas de evolución en modelos de procesamiento del lenguaje. Comprender esa evolución nos ayuda a valorar por qué los Transformers marcaron un antes y un después.

IA Generativa

Es un subconjunto del aprendizaje automático (ML), que se basa en métodos del aprendizaje profundo (DL)

Su funcionamiento pasa por recopilar información sobre determinados elementos que después servirán al modelo para generar otras ideas




Capacidad Generativa

Los modelos discriminativos asocian un dato proporcionado a una respuesta




Los modelos generativos generan nuevos datos en base a una distribución probabilística de respuestas



Una visión general

Comencemos por considerar el modelo como una única caja negra. En una aplicación de traducción automática, tomaría una frase en un idioma y generaría su traducción en otro.





La evolución de los modelos



Limitaciones de los modelos anteriores

1

RNN (Redes Neuronales Recurrentes)

Procesan datos secuenciales, pero olvidan información a largo plazo.

2

LSTM y GRU

Mejoran la memoria, pero siguen siendo lentos y difíciles de paralelizar.

3

Entrenamiento secuencial

No permite aprovechar del todo las GPUs modernas.





¿Qué aportan los Transformers?



Procesan entradas en paralelo, no paso a paso.



Permiten entrenar modelos con miles de millones de parámetros.



Usan el mecanismo de atención para enfocar en partes relevantes del input.



Son mucho más eficientes y escalables que sus predecesores.



Paper clave: "Attention is All You Need" (2017)



Este artículo revolucionó el campo del NLP al proponer una arquitectura sin recurrencias ni convoluciones, basada únicamente en atención.



Desde entonces, ha sido la base para modelos como BERT, GPT y T5.



Línea del tiempo: la evolución de los modelos

- ✓ 2013: Word2Vec (representaciones vectoriales de palabras).
- ✓ 2015: Seq2Seq con atención (Google Translate)
- ✓ 2017: Transformer (Attention is All You Need)
- ✓ 2018-2020: BERT, GPT-2, T5 2020-2023: GPT-3, Codex, PaLM, LLaMA
- ✓ 2018-2020: BERT, GPT-2, T5 2020-2023: GPT-3, Codex, PaLM, LLaMA



Arquitectura del Transformer



¿Qué es un Transformer?

Es una arquitectura de red neuronal diseñada para procesar secuencias enteras en paralelo, utilizando mecanismos de atención en lugar de recurrencia. Supone un salto radical en eficiencia y rendimiento respecto a los modelos previos.



Tokenización

Una vez que los textos han sido depurados y filtrados, es fundamental convertirlos en una representación matemática (token) que sea comprensible para una máquina.


En un futuro distópico donde el sol apenas ilumina la Tierra, un grupo de científicos descubre una anomalía en el cielo: una brecha dimensional que conecta nuestro mundo con una realidad alterna. La protagonista, Elara Voss, una astrofísica marcada por la pérdida de su familia, lidera una expedición para atravesar la brecha con la esperanza de revertir el colapso climático que azota el planeta. Lo que encuentran al otro lado desafía toda lógica: una Tierra paralela donde la humanidad nunca existió, y la naturaleza evolucionó sin límites. Sin embargo, ese mundo también tiene secretos oscuros. Criaturas hechas de energía pura comienzan a invadir su dimensión, y Elara debe tomar una decisión que podría salvar o condenar a ambos mundos. Con una mezcla de ciencia ficción, drama y suspenso, Sombras del Horizonte es una historia sobre la esperanza, el sacrificio y los límites del conocimiento humano.



1011010010110101010010101101101010011010100110110010101
0100110101011011010100110101001101100101010100110101011
0110101001101010011011001010101001101010110101001101
0100110110010101010011010101101101010011010100110110010
1010100110101011011010100110101001101100101010100110101
0110110101001101010011011001010101001101010110110101001
1010100110110010101010011010101101101010011010100110110
0101010100110101011011010100110101001101100101010100110
1010110110101001101010011011001010101001101010110110101
0011010100110110010101010011010101101101010011010100110
1100101010100110101011011010100110101001101100101010100
11010101101101010011010100110110

Una visión general

Se trata de representaciones vectoriales densas de palabras, frases o documentos, también conocidas como incrustaciones o vectores de representación, que permiten capturar tanto relaciones semánticas como contextuales a partir del análisis de grandes cantidades de texto.



Training

Utilizando ventanas de tokens de tamaño variable, la red neuronal se entrena asignando probabilidades a los distintos tokens del corpus. Luego, al comparar esas predicciones con el token real, se ajustan los pesos de la red con base en el error cometido.

Este procedimiento se repite una enorme cantidad de veces, lo cual implica un alto costo computacional.

	única	6.1%
	una	18.8%
	entidad	17.3%
	academia	29.1%
	plátano	0.3%
	coche	0.0002%

	única	17.4%
	una	17.2%
	entidad	15.4%
	academia	2.3%
	plátano	0.7%
	coche	0.0005 %



Estructura general del Transformer

Un Transformer se compone de capas repetidas que incluyen mecanismos de atención y redes feed-forward.

- ✓ Encoder: procesa la entrada
- ✓ Decoder: genera la salida, utilizando tanto la entrada como el contexto generado



Flujo de datos dentro del modelo

- 1

El input se convierte en embeddings

- 2

Se suma la codificación posicional

- 3

Se aplica atención múltiple
- 4

Se procesa con una red feed-forward

- 5

Se normaliza y pasa a la siguiente capa

- 6

En el decoder, se usa “self-attention” y “encoder-decoder attention”



¿Por qué funciona tan bien esta arquitectura?

1

Paralelización total

Aprovecha mejor las GPUs.

2

Atención directa

Accede a cualquier parte del input sin importar la distancia.

3

Escalabilidad

Permite modelos con miles de millones de parámetros.

4

Modularidad

Se adapta a tareas muy diversas (traducción, texto, código, imágenes, etc.)



Mecanismo de atención



¿Qué es la atención en IA?

Es la capacidad del modelo para decidir a qué partes de la entrada debe “prestar atención” para entender o generar una respuesta. Permite enfocarse en la información más relevante en cada momento del procesamiento.



El núcleo del Transformer: atención escalada

- ✓ Se basa en tres vectores: Q (query), K (key) y V (value)
- ✓ Calcula qué tan relevante es cada token respecto a los demás
- ✓ Produce una combinación ponderada de los valores en función de las similitudes
- ✓ Se normaliza con softmax para convertirlo en pesos



Se normaliza con softmax para convertirlo en pesos

- ✓ El modelo aplica múltiples mecanismos de atención en paralelo
- ✓ Cada “head” se enfoca en una relación distinta dentro del texto
- ✓ Esto permite captar significados complejos y relaciones cruzadas
- ✓ El resultado se concatena y se proyecta a una única representación



Atención: el superpoder de los Transformers

1

Captura dependencias a largo plazo sin esfuerzo

2

**No necesita leer en orden:
puede mirar toda la secuencia**

3

Permite que el modelo entienda contexto, ambigüedad y relaciones semánticas



Capacidades y usos de los LLMs



¿Qué son los LLMs?

Los LLMs (Large Language Models) son modelos entrenados con enormes cantidades de texto para predecir y generar lenguaje humano. Son la base de sistemas como ChatGPT, Claude, Gemini o LLaMA.



¿Qué pueden hacer los LLMs?

1 Generar texto coherente y contextualizado

2 Traducir entre idiomas

3 Resumir documentos extensos

4 Responder preguntas complejas

5 Escribir código, fórmulas, emails o poesía

6 Simular conversaciones, personajes o expertos



Capacidades cognitivas emergentes

1

Razonamiento lógico

Resolver problemas paso a paso

2

Comprensión de instrucciones

Seguir prompts detallados

3

Memoria contextual

Mantener coherencia en diálogos largos

4

Adaptabilidad

Cambiar de tono, formato o estilo según el caso



Aplicaciones en el mundo real

1

Atención al cliente: chatbots, resúmenes de tickets, clasificación de consultas

2

Marketing y contenido: redacción de textos, generación de copies y campañas

3

Educación: tutores virtuales, generación de tests, explicaciones simplificadas

4

Legal y compliance: análisis de contratos, redacción asistida, verificación de riesgos

5

Programación: generación de código, refactorización, documentación automática



Limitaciones actuales

1

Alucinaciones

Pueden inventar información.

2

Sesgos

Se reflejan prejuicios del corpus de entrenamiento.

3

Falta de sentido común

No entienden, solo predicen.


4

Actualización limitada

No siempre conocen eventos recientes.



Atención: el superpoder de los Transformers



Texto de entrada

El usuario escribe una pregunta, instrucción o fragmento de texto.

Modelo LLM

El modelo LLM (como GPT) analiza el contexto y predice la mejor continuación palabra por palabra.

Texto de salida

Como resultado, genera una respuesta coherente y relevante en lenguaje natural.



¿Cómo funcionan?

Utilizan mecanismos de atención para comprender el contexto completo de una frase.

Son pre-entrenados con grandes volúmenes de texto de internet y puede ajustarse para tareas específicas.

Cuanto mayor es el número de parámetros, mejor capta los matices del lenguaje.

GPT-4, por ejemplo, tiene billones de parámetros y es capaz de generar texto fluido, coherente y relevante en múltiples idiomas y contextos.

- ✓ Entrada: Texto creado por un usuario e introducido al modelo
- ✓ Tokenización: Divide el texto en fragmentos comprensibles
- ✓ Transformer: Atenúa lo relevante del contexto
- ✓ Predicción: Genera palabra por palabra hasta completar la respuesta



¿Qué son las alucinaciones de la IA?

Las alucinaciones son errores: cuando la IA inventa datos que suenan reales pero no lo son.”

La IA predice la palabra más probable, no la verdad.
Cuando escribimos con ayuda de una IA, es importante entender cómo funciona: no piensa, no sabe, no verifica.

Lo que hace es predecir cuál palabra viene después según patrones aprendidos de millones de textos. Eso significa que puede generar frases que suenan correctas... pero no lo son. Por eso, no podemos asumir que todo lo que dice es cierto: debemos revisar, contrastar y validar.

1

Ejemplo 1: Gabriel García Márquez ganó el Premio Nobel en 1971.” (Incorrecto, fue en 1982)

2

Ejemplo 2: $3 + 3 = 5$ (Incorrecto, es 6)



¿Por qué ocurren las alucinaciones?



Texto de salida 1

El ornitorrinco es uno de los pocos mamíferos que pone huevos.

Texto de salida 2

El armadillo es el único mamífero que pone huevos.

Texto de entrada

El usuario escribe una pregunta, instrucción o fragmento de texto.

Modelo LLM

El modelo LLM (como GPT) analiza el contexto y predice la mejor continuación palabra por palabra.



Estrategias para prevenir errores

Validación de hechos

- ✓ Siempre que la IA proporcione datos, nombres, fechas o cifras, es fundamental contrastarlos con fuentes confiables. La verificación externa asegura la precisión y evita difundir errores con apariencia de verdad.

Revisión manual

- ✓ Aunque la IA puede generar textos coherentes, solo una persona puede evaluar el contexto, el tono y la intención correcta. Leer y editar el contenido final es indispensable para garantizar calidad y coherencia con tu propósito.

Uso como borrador, no como fuente definitiva

- ✓ La IA es una excelente herramienta para generar primeros borradores, ideas iniciales o versiones tentativas. No debe ser usada como única fuente de información, sino como punto de partida que requiere revisión y ajustes humanos.



Estrategias para prevenir errores

El Zoológico de Berlín es uno de los más antiguos del mundo, fundado en 1745. Alberga más de 30.000 especies, incluyendo animales raros como el oso polar asiático. Este zoológico también es conocido por sus programas de conservación y su arquitectura histórica. Además, ha sido visitado por más de 100 millones de personas desde su apertura.

- 1

Validación de hechos
Verificar fechas con una fuente confiable (1844)
-
- 2

Revisión manual
Sospechar de cifras extremas o redondas. (1.200 especies)
-
- 3

Uso como borrador
Buena base para texto, pero debe ajustarse antes de usarse. (ártico)



¿Cómo generan texto los LLMs?

Los modelos de lenguaje no escriben de forma consciente: predicen el siguiente token (fragmento de palabra) basándose en los anteriores. Esa simple operación, repetida miles de veces por segundo, da lugar a texto fluido y coherente.



Predicción token a token

- ✓ El modelo no genera frases completas, sino un token a la vez
- ✓ En cada paso, calcula la probabilidad de todos los posibles siguientes tokens
- ✓ Selecciona uno y lo añade al contexto
- ✓ Repite el proceso hasta alcanzar un límite o un token de cierre



Sampling: cómo se elige el siguiente token

1

Greedy decoding

Siempre elige el token más probable

2

Top-k sampling

Elige aleatoriamente entre los k tokens más probables

3

Top-p (nucleus sampling)

Elige de un subconjunto acumulado hasta alcanzar p% de probabilidad

4

Temperatura

Controla la aleatoriedad (baja = más preciso, alta = más creativo)



Comportamiento según parámetros de generación

Los parámetros como temperatura, top-k o top-p afectan directamente al estilo del texto generado:

- 1 Temperatura 0.1: texto directo, factual, repetitivo
- 2 Temperatura 0.9: más creativo, impredecible

Top-p 0.8 tiende a generar resultados más diversos que greedy decoding



Estrategias para prevenir errores

Causal (autoregresivos)

- ✓ Predicen token por token solo hacia adelante (GPT)

Bidireccional

- ✓ Consideran el contexto completo antes y después (BERT)

Importancia

- ✓ GPT se usa para generación, BERT para clasificación y comprensión



Modelos más importantes

¿Quiénes son los grandes jugadores en LLMs?

Desde 2020, varios laboratorios y empresas han desarrollado modelos de lenguaje cada vez más potentes. Aunque comparten fundamentos similares, cada uno tiene enfoques y capacidades distintas.



Principales modelos de uso

GPT-3.5 / GPT-4 — OpenAI
(ChatGPT) Claude — Anthropic Gemini — Google
DeepMind LLaMA — Meta (open source)
Mistral / Mixtral — Lightweight y rápidos, también open source
Command R / Cohere — Enfoque en RAG y enterprise



Comparativa general

1

Propietarios vs Open SourceGPT-4

Claude, Gemini → acceso vía API
LLaMA, Mistral → puedes alojarlos tú

2

Tamaño y coste

GPT-4 y Gemini: modelos más grandes y potentes, pero más caros
Mistral y LLaMA: más ligeros, ideales para proyectos locales

3

Capacidades

Algunos son multimodales (texto + imagen)
Otros están optimizados para tareas específicas (RAG, código)



¿Cómo elegir el modelo adecuado?

- ✓ ¿Necesitas acceso inmediato y resultados de alta calidad? → GPT-4 o Claude
- ✓ ¿Prefieres control total sobre el modelo? → LLaMA, Mistral
- ✓ ¿Tu caso de uso requiere coste bajo y velocidad? → Mistral o GPT-3.5
- ✓ ¿Tu app necesita trabajar con imágenes? → Gemini o GPT-4 (multimodal)



Autenticación, claves y configuración básica



¿Qué es una clave de API?

Una clave de API es un identificador único que permite autenticar a un usuario o aplicación cuando realiza peticiones a un servicio.

Sirve para:

- 1 Controlar el acceso a los modelos de IA.
- 2 Registrar el uso para monitoreo y facturación.
- 3 Establecer límites y políticas de seguridad.



Cómo obtener una clave de API

OpenAI

- ✓ Crear cuenta en <https://platform.openai.com>
- ✓ Ir a API keys > Create new secret key.
- ✓ Guardarla (solo se muestra una vez).

HuggingFace

- ✓ Crear cuenta en <https://huggingface.co>
- ✓ Ir a Settings > Access Tokens > New Token.

Importante

Nunca compartas ni subas tu clave a repositorios públicos.



Formas de autenticarse en una API

La clave se incluye generalmente en el encabezado de la petición HTTP:

- 1 **Authorization: Bearer TU_API_KEY**

En algunos casos (menos seguros), se acepta como parámetro en la URL:
`https://api.ejemplo.com/endpoint?api_key=TU_API_KEY`

- 1 **Lo más común en IA generativa es usar Bearer Tokens por encabezado.**
- 2 **Asegúrate de usar HTTPS para proteger tu clave.**



Buenas prácticas en el uso de claves API

- ✓ No publiques tu clave (ni en GitHub ni en notebooks compartidos).
- ✓ Usa variables de entorno para guardarlas en tu código.
- ✓ Rota las claves periódicamente.
- ✓ Si una clave se filtra, revócala de inmediato.
- ✓ Revisa los logs de uso desde el panel del proveedor.



