

Estimación de la duración de procesos en una asesoría

Entrega 4 — Modelo, baselines y detección de anomalías

Índice

Respuesta al feedback de las entregas 2 y 3	2
1. Problema y alcance	3
1.1 Qué se estima	3
1.2 Por qué una sola línea	3
1.3 Qué pipeline y por qué	4
2. Datos	5
2.1 Origen y cadena de enlace	5
2.2 Unidad de observación	5
2.3 Volumen y ventana	5
2.4 Variable objetivo	5
2.5 Datos que no salen del sistema	5
3. Calidad de datos	5
3.1 Granularidad del target: el suelo del error	6
3.2 Distribución del target	6
3.3 Censura	6
3.4 Cobertura y coherencia	6
4. Metodología	7
4.1 Filtros de inclusión	7
4.2 Features	7
4.3 Validación y regla anti-leakage	8
5. Baselines	8
6. Resultados	9
6.1 Modelos evaluados	9
6.2 Bucle de mejora, con criterio de parada declarado antes de abrirlo	10
6.3 Resultado en el split temporal 2025 □ 2026	10
6.4 Estabilidad en GroupKFold(4) por cliente	11
6.5 Lectura del resultado	11
6.6 Predicción por intervalos	11
7. Explicabilidad	12
7.1 Modelo de control	12
8. Anomalías	12
8.1 Definición	12
8.2 Tasa de marcado	13

8.3 Una limitación aritmética de la definición	13
8.4 Validación ciega con experto	13

9. Limitaciones declaradas 14

10. Trabajo futuro y estado de la entrega 14

10.1 Qué desbloquearía cada línea	14
10.2 Seguridad y reproducibilidad	15
10.3 Lo que queda pendiente	15
10.4 Trazabilidad de las cifras	15

Respuesta al feedback de las entregas 2 y 3

Observación del tutor	Qué se ha cambiado	Dónde verlo
Abarcaba predicción, anomalías y segmentación a la vez	Una sola línea: estimación de duración. La anomalía es el residuo del mismo modelo, no un modelo aparte	§ 1 Problema y alcance; § 8 Anomalías
19 meses no permiten predecir 2027	Se abandona la extrapolación temporal. Regresión transversal: una negociación ejecutada es una observación	§ 1 Problema y alcance; § 4 Metodología
Muy pocos meses por cliente	La unidad pasa de cliente $\times$ mes a negociación. 13.013 observaciones sobre 1.036 clientes	§ 2 Datos
Afirmar acceso garantizado y calidad excelente sin explorar	Fase de calidad ejecutada antes de escribir la memoria, con cifras. El 21,74 % de las negociaciones cerradas del pipeline tiene 0 minutos imputados y el 11,71 % de las horas no cuelga de ninguna negociación	§ 3 Calidad de datos
No demostraba mejorar un análisis sencillo	Cuatro baselines calculados antes que el modelo. B1 (mediana por proceso) fijado como referencia: MAE 16,37 min. El modelo mejora un 5,31 %, por debajo del 10 % que se había fijado como umbral, y así se reporta	§ 5 Baselines; § 6 Resultados
Sin plan contra el leakage temporal	Split temporal por campaña (cierres de 2025 frente a cierres de 2026) y GroupKFold(4) por cliente. Features históricas con ventana expansiva estricta	§ 4.3 Validación y regla anti-leakage
pct_rentabilidad rellenado con 0 e imputación de costes por medias	Métrica eliminada del alcance. No se usa facturación ni costes en ninguna parte del proyecto	§ 1 Problema y alcance

Observación del tutor	Qué se ha cambiado	Dónde verlo
IPs y nombres de base de datos en el repositorio	Todas las conexiones por <code>.env</code> , que no se versiona. Comprobación automática antes de cada commit (<code>src/_check_seguridad.py</code>) sobre lo que se va a versionar	§ 10.2 Seguridad
Trabajo mezclado con carpetas ajenas	No resuelto todavía. El material está preparado para extraerse a un repositorio dedicado, pero la creación del repositorio nuevo y la purga del historial antiguo son acciones pendientes de ejecución manual, registradas con los pasos exactos	BLOQUEOS.md, B-003

La última fila queda abierta a propósito. El contenido está listo para moverse, pero el repositorio independiente no existe aún.

1. Problema y alcance

1.1 Qué se estima

Cuántos minutos lleva ejecutar un proceso de asesoría, a partir de características del proceso y del cliente conocidas **antes** de empezarlo.

Del mismo modelo salen dos usos:

Uso	Momento	Cómo
Planificación	Antes de ejecutar	La predicción estima la carga de trabajo
Control	Al cerrar la campaña	El residuo estandarizado señala lo anómalo

La detección de anomalías no es un segundo modelo. Si el modelo estima 24 min para un proceso y se han imputado 1.004, ese residuo es la señal. No se entrena ningún detector independiente.

1.2 Por qué una sola línea

Las versiones anteriores del proyecto abarcaban predicción de rentabilidad, detección de anomalías y segmentación de clientes a la vez, y planteaban la predicción como un problema temporal: extrapolar a 2027 con 19 meses de histórico y con la unidad de observación cliente × mes.

Este planteamiento cambia las tres cosas:

Antes	Ahora	Efecto medible
Tres líneas simultáneas	Una: duración	La anomalía se calcula con el mismo modelo, sin ajustar nada aparte

Antes	Ahora	Efecto medible
Serie temporal a 2027	Regresión transversal	Cada ejecución cerrada es una observación; no se extrapola fuera del rango observado
Unidad cliente × mes	Unidad negociación	13.013 observaciones frente a agregados mensuales con pocos puntos por cliente
Bitrix y un segundo sistema de facturación	Solo el CRM	Se elimina la dependencia de costes y facturación, origen de la crítica sobre pct_rentabilidad

1.3 Qué pipeline y por qué

El trabajo de la asesoría está organizado en negociaciones del CRM repartidas en pipelines. El alcance de esta entrega es el pipeline **Modelos de impuestos**.

Razones, con las cifras que las sostienen:

Criterio	Cifra
Etiqueta nativa del proceso, sin heurística de texto	El campo <i>Modelo presentado</i> del CRM tiene 52 valores de lista; 16.941 de las 17.223 negociaciones del pipeline lo tienen relleno (98,4 %)
Repeticiones suficientes por clase	25 valores de proceso con 30 o más negociaciones cerradas con tiempo; el más frecuente tiene 3.943
Permite validación temporal	6.821 negociaciones cerradas en 2025 y 6.192 en 2026, seis campañas trimestrales en la ventana

Qué queda fuera y por qué:

Ámbito	Estado	Motivo
Contabilidad (Contabilidad Interna, Contabilidad Externa, Cierres)	Extensión 1	Sirve para comprobar si el método se transfiere. Volumen disponible: 10.347,6 h imputadas frente a las 3.703,0 h del pipeline objetivo
Rentas	Extensión 2	Solo dos campañas (2025 y 2026). Una campaña es un único bloque temporal: no admite validación en el tiempo
Resto de pipelines	Fuera	—

El código recibe el pipeline y el nombre de la columna de tipo de proceso como parámetros (PIPELINE_OBJETIVO en `src/01_extraccion.py`, `src/02_edat.py` y `src/03_dataset.py`). Ejecutarlo sobre contabilidad no requiere tocar la lógica.

2. Datos

2.1 Origen y cadena de enlace

Los datos provienen de la base de datos del CRM de la asesoría, en modo de solo lectura. La cadena que conecta el tiempo con el proceso es:

imputación de tiempo → tarea → (campo UF_CRM_TASK = 'D_<id>') → negociación → pipeline

La tabla puente resultó llamarse `b_utm_tasks_task` y no `b_utm_task`, y el motor es MySQL 5.7, sin soporte de expresiones `WITH` ni funciones de ventana. Ambas discrepancias están registradas en `BLOQUEOS.md` (B-001 y B-002) y resueltas.

2.2 Unidad de observación

Una negociación cerrada es una observación. No la tarea, no la imputación individual, no el cliente × mes. Cada negociación del pipeline es una ejecución concreta de un proceso para un cliente: presentar un modelo 303 de un trimestre, presentar un 200 de un ejercicio.

2.3 Volumen y ventana

Ventana de extracción: negociaciones creadas o cerradas desde el 1 de enero de 2025.

Conjunto	Filas
Negociaciones de todos los pipelines	30.836
Imputaciones de tiempo con negociación asociada	66.690
Negociaciones del pipeline objetivo	17.223
Negociaciones del dataset modelable	13.013
Cientes distintos en el dataset modelable	1.036
Empleados distintos que imputan tiempo	46
Rango de fechas de cierre en el dataset	3 de enero de 2025 a 25 de agosto de 2026

2.4 Variable objetivo

`minutos_total` = suma de los segundos imputados en las tareas de la negociación, dividida entre 60. Se modela $\log_{10}(\text{minutos_total})$ y todas las métricas se reportan en minutos, deshaciendo la transformación con `expm1`.

2.5 Datos que no salen del sistema

Ningún archivo del repositorio contiene nombres de empresa, NIF, nombres de contacto, direcciones, teléfonos, correos, nombres de empleado, títulos de tarea ni el texto de los comentarios de las imputaciones. Clientes y empleados se identifican solo por identificador numérico. Los nombres de pipeline, de etapa y los valores de lista (303, 111, 200, CCT) sí se usan: son categorías de proceso.

3. Calidad de datos

Todas las cifras de esta sección salen de `src/02_edu.py` y están en `output/02_informe_calidad.md`.

3.1 Granularidad del target: el suelo del error

El target es tiempo imputado por una persona. Si ese tiempo se declarase en bloques redondos, el modelo no podría bajar de la granularidad de esos bloques. Reparto de las 66.690 imputaciones:

Granularidad	n	%
Múltiplo exacto de 60 min	536	0,80
Múltiplo exacto de 30 min	455	0,68
Múltiplo exacto de 15 min	837	1,26
Múltiplo exacto de 5 min	2.236	3,35
Valor no redondo	62.626	93,91

El 93,91 % de las imputaciones tiene un valor no redondo. El tiempo se registra con un cronómetro, no por estimación en bloques. Esto elimina el techo de granularidad que se esperaba encontrar, pero no elimina el resto del ruido de imputación: lo que se mide es cuándo alguien arrancó y paró un contador, no el esfuerzo real.

3.2 Distribución del target

Sobre las 13.388 negociaciones cerradas con tiempo del pipeline objetivo:

Estadístico	Valor (min)
Mediana	5,5
P99	169,4
Máximo	1.003,7
Ratio P99 / mediana	30,8

La cola es larga: el percentil 99 está 30,8 veces por encima de la mediana. Esto justifica modelar $\log_{10}$ y evaluar con MAE y MedAE en lugar de RMSE, que quedaría dominado por unos pocos casos.

3.3 Censura

Estado	n	%
Cerrada y ganada	14.876	86,37
Cerrada y perdida	2.257	13,10
En curso	90	0,52

Se modela solo lo cerrado y ganado. Las 2.257 perdidas y las 90 en curso quedan fuera: son censura por la derecha, no ruido.

3.4 Cobertura y coherencia

Comprobación	Valor
Horas imputadas que no cuelgan de ninguna negociación	11,71 % (4.066,6 h de 34.721,4 h)
Negociaciones cerradas del pipeline con 0 minutos imputados	21,74 % (3.745 de 17.223)

Comprobación	Valor
Negociaciones con más de un empleado imputando	3,84 %
Negociaciones con más de 8 h imputadas	0,06 % (8 de 13.388)
Negociaciones con menos de 1 minuto imputado	7,31 % (978 de 13.388)
Imputaciones fechadas fuera de la ventana [creación, cierre] de su negociación	1,65 %
Días entre creación y cierre (mediana)	14
Días entre primera y última imputación (mediana)	0

Las dos primeras filas son las que más condicionan el alcance del modelo: casi el 12 % del tiempo registrado no es atribuible a ningún proceso, y más de una de cada cinco negociaciones cerradas no tiene tiempo imputado. El modelo aprende del trabajo que llegó a registrarse contra un proceso, no de todo el trabajo hecho.

4. Metodología

4.1 Filtros de inclusión

Filtro	Filas antes	Filas caídas	Filas después
Pipeline = Modelos de impuestos	30.836	13.613	17.223
Negociación cerrada	17.223	90	17.133
Semántica ganada	17.133	2.257	14.876
Minutos imputados > 0	14.876	1.738	13.138
Valor de proceso no vacío	13.138	125	13.013
Fecha de cierre no nula	13.013	0	13.013

Además, en la extracción se descartan las tareas enlazadas a más de una negociación, para no duplicar su tiempo: 5 tareas, 3 imputaciones y 1,98 h sobre 30.654,8 h con negociación (0,006 %).

4.2 Features

Modelo de **planificación**, el principal. Solo información conocida antes de ejecutar el proceso.

Feature	Tipo	Nulos (%)
proceso	categorica	0,00
ejercicio	numérica	21,18
trimestre_fiscal	categorica derivada	0,00
mes_creacion	categorica	0,00
dias_desde_alta_cliente	numérica	0,11
n_procesos_previos_cliente	numérica histórica	0,00
mediana_min_cliente_hist	numérica histórica	17,23
mediana_min_proceso_hist	numérica histórica	17,31
n_deals_misma_campana	numérica	0,00
es_primera_vez_cliente_proceso	binaria	0,00

trimestre_fiscal se deriva como el trimestre natural de (fecha_creacion – 1 mes). El CRM tiene un campo *Periodo*, pero solo toma valor trimestral en 6.138 de las 13.013 filas (47,2 %); el resto son valores anuales,

mensuales o de pago fraccionado. Sobre esas 6.138 filas comparables, la regla derivada coincide con el valor declarado en el 99,63 % de los casos. La decisión, con la alternativa descartada, está en DECISIONES.md (D-006).

El modelo de **control** añade responsable_id_grp (responsables con menos de 30 casos agrupados en OTROS) y n_empleados. Se entrena y se reporta por separado.

Features excluidas por conocerse solo después de ejecutar el proceso: minutos_max_imputacion, n_imputaciones, n_tareas, n_empleados, fecha_ultima_imputacion, fecha_cierre, fecha_primera_imputacion, etapa, etapa_id, semantica, cerrada. La única excepción es n_empleados, reservada al modelo de control. src/03_dataset.py comprueba la ausencia de todas ellas y aborta si alguna aparece.

4.3 Validación y regla anti-leakage

Regla aplicada: toda feature histórica se calcula usando exclusivamente negociaciones cuya fecha_cierre es **estrictamente anterior** a la fecha_creacion de la fila que se está construyendo. Ventana expansiva, nunca el conjunto completo.

Las filas sin historial suficiente reciben NaN, no la media global: rellenar con un estadístico calculado sobre todo el conjunto sería leakage encubierto. El coste de esta decisión está medido: 2.242 filas (17,2 %) quedan sin historial de cliente y 2.253 (17,3 %) sin historial de proceso.

Particiones:

Partición	Definición	Filas	Clientes
Train	Negociaciones cerradas en 2025	6.821	894
Test	Negociaciones cerradas en 2026	6.192	917
Validación interna	GroupKFold(n_splits=4) — agrupando por cliente, dentro de train	—	—

El agrupamiento por cliente evita que un mismo cliente aparezca a ambos lados del corte. Su efecto es verificable en la tabla de baselines: B3, que corrige por la mediana histórica del cliente, obtiene exactamente el mismo MAE que B1 en los cuatro folds, porque ningún cliente de validación aparece en el ajuste.

Comprobación de leakage: asociación de cada feature con el target dentro de train. Ninguna supera 0,95. La más alta es proceso, con una razón de correlación de 0,441.

random_state=42 en todo lo que tiene aleatoriedad.

5. Baselines

Calculados **antes** que el modelo, para no ajustar el listón. Los cuatro se ajustan solo con train y se evalúan en test.

Id	Definición
Bo	La mediana de train, para todas las filas
B1	La mediana de train del mismo valor de proceso
B2	La mediana de train de proceso × ejercicio, con retroceso a B1 y a Bo

Id	Definición
B3	B1 multiplicado por (mediana del cliente en train / mediana global de train), con el factor acotado a $[0,2 \cdot 5,0]$

Resultado en el split temporal, todas las métricas en minutos:

Baseline	MAE	MedAE	% ± 5 min	% ± 15 min	% ± 30 min	RMSE	MAPE (%)
Bo mediana global	16,39	3,90	63,47	77,70	86,48	43,42	150,94
B1 mediana por proceso	16,37	4,88	50,95	72,37	88,53	41,05	247,34
B2 proceso $\times$ ejercicio	16,40	4,88	50,95	72,29	88,55	41,05	249,45
B3 proceso ajustada por cliente	17,77	5,40	48,18	72,67	85,90	44,70	295,80

B1 queda fijado como referencia del proyecto: MAE = 16,37 min.

Dos observaciones que la tabla obliga a hacer:

1. B1 solo mejora a Bo en 0,02 min de MAE. Conocer el tipo de proceso apenas reduce el error medio, aunque sí cambia el reparto: Bo tiene mejor MedAE (3,90 frente a 4,88) y mejor porcentaje dentro de ± 5 min (63,47 frente a 50,95). B1 acierta mejor en la cola y peor en el centro.
2. B3 empeora a B1 en 1,40 min. Corregir por la mediana histórica del cliente perjudica la predicción en este pipeline.

Sobre % ± 15 min y % ± 30 min: con una mediana de 5,1 min en train, una ventana de 15 o 30 minutos cubre casi toda la distribución y las dos métricas se saturan. Se incluyen porque el guion de la entrega las pide, y se añade % ± 5 min, que sí discrimina en esta escala.

MAPE se reporta solo como información. Con negociaciones de menos de un minuto (7,31 % del dataset) el denominador se acerca a cero y la métrica se dispara; no se usa para decidir nada.

6. Resultados

6.1 Modelos evaluados

Id	Modelo
M1	Regresión lineal sobre log1p con codificación one-hot
M2	HistGradientBoostingRegressor
M3	M2 con pérdida cuantílica, $q = 0,1 / 0,5 / 0,9$

6.2 Bucle de mejora, con criterio de parada declarado antes de abrirlo

Elemento	Valor
Métrica	MAE en minutos sobre la validación interna GroupKFold(4) por cliente
Umbral	Mejora $\geq 10\%$ sobre el MAE de B1 en esa misma validación (11,53 min)
Intentos máximos	5, en el orden de la lista prevista
Papel del test	Ninguno en la decisión de parada

Trayectoria completa:

Intento	MAE validación (min)	Mejora sobre B1 (%)	MAE test (min)
0. M2 con las features de partida	11,33	1,67	15,91
1. Agrupar procesos con <100 casos en OTROS	11,34	1,63	15,61
2. Añadir features de carga de campaña	11,36	1,45	15,61
3. Ajustar max_iter / learning_rate / max_leaf_nodes	11,26	2,28	15,50
4. Target encoding por cliente ajustado dentro de cada fold	12,14	-5,31	15,80
5. Recortar la cola al P99 solo en train	11,26	2,28	15,48

Se agotaron los 5 intentos sin alcanzar el 10 %. La variante seleccionada es la 3, la mejor en validación interna. No es la mejor en test (la 5 obtiene 15,48 frente a 15,50), lo que confirma que la selección no miró el conjunto de evaluación.

6.3 Resultado en el split temporal 2025 □ 2026

Modelo	MAE	Mejora sobre B1 (%)	MedAE	% ± 5 min	% ± 15 min	% ± 30 min	RMSE	MAPE (%)
B1 (referencia)	16,37	0,00	4,88	50,95	72,37	88,53	41,05	247,34
M1 regresión lineal	16,40	-0,18	5,91	44,62	74,63	87,90	40,82	263,03
M2 gradient boosting	15,50	5,31	4,65	52,05	80,17	88,00	41,73	180,35
M3 cuantil 0,5	15,37	6,11	4,42	53,42	80,02	88,28	41,49	170,81

Modelo	MAE	Mejora sobre B1 (%)	MedAE	% ± 5 min	% ± 15 min	% ± 30 min	RMSE	MAPE (%)
Modelo de control	14,94	8,74	5,18	49,03	78,81	89,26	39,14	245,52

6.4 Estabilidad en GroupKFold(4) por cliente

Fold	MAE B1	MAE M1	MAE M2	Mejora de M2 (%)
1	11,72	11,93	11,42	2,56
2	11,42	11,61	11,23	1,66
3	12,14	12,18	11,88	2,14
4	10,82	10,73	10,52	2,77

M2 mejora a B1 en 4 de 4 folds. La mejora es pequeña pero no es inestable.

6.5 Lectura del resultado

El modelo no alcanza el umbral fijado. M2 reduce el MAE de 16,37 a 15,50 min, una mejora del 5,31 % frente al 10 % declarado como criterio. Se reporta así, sin tocar el test, sin filtrar casos difíciles y sin reajustar el baseline a la baja.

Tres cifras ya medidas explican por qué el margen es estrecho:

1. **La distribución está dominada por la cola.** Ratio P99 / mediana = 30,8. Los dos mayores errores de test son negociaciones del proceso 347 con 1.003,7 y 795,4 minutos imputados, frente a una mediana histórica de ese proceso de 22,8 min. Ninguna feature disponible antes de ejecutar el proceso anticipa esa diferencia.
2. **Hay deriva entre las dos campañas.** El P99 de minutos_total pasa de 143,7 min en train a 189,9 min en test, y el MAE de B1 pasa de 11,53 min en la validación interna a 16,37 min en el test temporal, un 42,0 % más. Parte del error de 2026 no estaba presente en los datos de 2025.
3. **El target no recoge todo el trabajo.** El 11,71 % de las horas imputadas no cuelga de ninguna negociación y el 21,74 % de las negociaciones cerradas del pipeline tiene 0 minutos imputados.

La conclusión sustantiva es que la duración de estos procesos está determinada principalmente por el tipo de proceso y por el nivel histórico de tiempo del cliente, y el resto de la variación procede de cada ejecución concreta y del hábito de imputación. Un modelo con estas features no puede reducir mucho más el error.

Esto no invalida el uso de planificación: M2 sitúa el 80,17 % de las negociaciones dentro de ± 15 min frente al 72,37 % de B1, y el 52,05 % dentro de ± 5 min frente al 50,95 %. Para estimar la carga de una campaña completa, la diferencia entre 16,37 y 15,50 min de error medio por negociación se acumula sobre miles de ejecuciones.

6.6 Predicción por intervalos

M3 produce un intervalo [q10, q90] con anchura mediana de 14,5 min. Ese intervalo contiene el valor real en el 54,80 % de las negociaciones de test, frente al 80 % nominal. Está mal calibrado, por la misma deriva entre campañas descrita arriba. No es utilizable como garantía de cobertura sin recalibrarlo por campaña.

7. Explicabilidad

Importancia por permutación sobre test, 10 repeticiones, random_state=42, medida como caída del MAE en la escala log1p al permutar cada columna.

Feature	Importancia media	Desviación
mediana_min_cliente_hist	0,0869	0,0030
proceso	0,0704	0,0043
n_procesos_previos_cliente	0,0138	0,0018
dias_desde_alta_cliente	0,0083	0,0008
mediana_min_proceso_hist	0,0058	0,0018
mes_creacion	0,0019	0,0010
n_deals_misma_campana	0,0015	0,0005
es_primera_vez_cliente_proceso	0,0009	0,0007
trimestre_fiscal	-0,0000	0,0003
ejercicio	0,0000	0,0000

Dos features aportan casi toda la señal: el nivel histórico de tiempo del cliente y el tipo de proceso. trimestre_fiscal y ejercicio aportan cero: en este pipeline, saber de qué trimestre o de qué ejercicio es la declaración no cambia cuánto se tarda en presentarla.

Dos casos individuales, los de mayor error absoluto en test:

deal_id	proceso	Mediana histórica del proceso	Mediana histórica del cliente	Minutos reales	Minutos predichos
31928	347	22,8	19,7	1.003,7	23,8
31899	347	22,8	6,5	795,4	7,8

En los dos casos el modelo predice cerca de la mediana histórica y el tiempo real la supera en más de un orden de magnitud. Son exactamente el tipo de caso que la sección 8 marca como anomalía.

7.1 Modelo de control

El modelo de control añade responsable_id_grp y n_empleados. Su MAE en test es 14,94 min frente a los 15,50 min del modelo de planificación, y responsable_id_grp ocupa la posición 2 de 12 en importancia por permutación.

Es un hallazgo, y se reporta como tal: quién ejecuta el proceso explica parte de la duración. La finalidad de este modelo es detectar anomalías de proceso, no evaluar el desempeño de personas. Por eso se entrena y se reporta por separado del modelo de planificación, que no incluye al responsable.

8. Anomalías

8.1 Definición

La anomalía es el residuo del modelo de la sección 6, estandarizado por la dispersión propia de cada proceso:

residuo = minutos_reales - minutos_predichos

sigma_proc = desviación típica de los residuos de train, por proceso

$z = \text{residuo} / \text{sigma_proc}$
 $\text{anomalía} = |z| > 3$

La sigma se estima con los residuos **out-of-fold** de train (GroupKFold por cliente). Usar residuos dentro de muestra la subestimaría y elevaría la tasa de marcado de forma artificial. Los procesos con menos de 20 casos en train usan la sigma global.

8.2 Tasa de marcado

Sobre las 6.192 negociaciones cerradas en 2026:

Tipo	n	%
Normal	5.953	96,14
Anomalía por exceso ($z > 3$)	239	3,86
Anomalía por defecto ($z < -3$)	0	0,00

Tasa global de marcado: 3,86 %, por debajo del 5 % que se había fijado como límite de manejabilidad.

8.3 Una limitación aritmética de la definición

No hay ninguna anomalía por defecto, y no es un hallazgo sobre los datos: es una consecuencia de la definición. Los minutos no son negativos, así que el residuo no puede bajar de $-\text{minutos_predichos}$. Con predicciones de pocos minutos y sigmas de decenas de minutos, el valor más negativo que z alcanza en todo el conjunto de test es **-0,043**, muy lejos de -3 . En escala de minutos, esta definición solo puede detectar exceso, y la sospecha de infraimputación que se pretendía cubrir queda fuera.

Por eso se calcula también la misma regla sobre el residuo en escala $\log_{10}$, donde el residuo sí es simétrico:

Definición	Marcadas	%	Por exceso	Por defecto	Volumen manejable (<5 %)
(a) Residuo en minutos, $ z > 3$	239	3,86	239	0	sí
(b) Residuo en escala $\log_{10}$, $ z > 3$	68	1,10	67	1	sí
(c) Fuera del intervalo $[q_{10}, q_{90}]$ de M_3	2.799	45,20	1.492	1.307	no

Se adopta **(a)** como definición principal: produce una lista revisable de casos con sobrecoste de tiempo. **(b)** se reporta como complemento, porque cubre el único caso que (a) no puede ver por construcción. **(c)** queda descartada por volumen: marcar el 45,20 % de las negociaciones no es una alerta, y además hereda el problema de calibración de la sección 6.6.

8.4 Validación ciega con experto

Se ha generado output/validacion_experto.csv con 40 casos: 20 marcados como anómalos y 20 normales, mezclados con random_state=42 y sin la columna de predicción ni la de z . Columnas: deal_id, proceso, ejercicio, minutos_total, veredicto_experto, esta última vacía y con valores admitidos razonable, anormal y no_se.

La clave (qué caso estaba marcado y con qué z) se guarda aparte, en `output/validacion_experto_clave.csv`, y no se entrega junto con el archivo de validación.

Estado: pendiente. El experto todavía no ha devuelto el archivo relleno. Cuando lo devuelva como `output/validacion_experto_relleno.csv`, al reejecutar `src/06_anomalias.py` se calculan el acuerdo, la precisión y el recall del marcado frente al criterio experto, y la sección 5.1 de `output/06_anomalias.md` se completa sola. No se rellena con cifras inventadas.

9. Limitaciones declaradas

1. **El target es tiempo imputado manualmente, no medido.** El modelo aprende tanto el esfuerzo real como el hábito de imputación. En este caso el registro es cronometrado —el 93,91 % de las imputaciones tiene un valor no redondo—, lo que descarta el redondeo en bloques como fuente principal de ruido, pero no garantiza que el cronómetro se arranque y se pare cuando empieza y acaba el trabajo.
2. **Solo se observan negociaciones cerradas y ganadas.** Las 2.257 pérdidas (13,10 %) y las 90 en curso (0,52 %) del pipeline quedan censuradas y fuera del modelo.
3. **El trabajo que no cuelga de ninguna negociación es invisible al modelo.** Son 4.066,6 h, el 11,71 % de las horas imputadas en la ventana. A esto se suma que el 21,74 % de las negociaciones cerradas del pipeline no tiene ningún minuto imputado.
4. **El histórico cubre un número limitado de campañas.** La validación temporal se apoya en los cierres de 2026 (6.192 negociaciones) frente a los de 2025 (6.821). Con dos años, la deriva medida entre campañas —el P99 pasa de 143,7 a 189,9 min— no puede separarse de la variación año a año.
5. **Los resultados son específicos de esta asesoría.** Dependen de su cartera de clientes, de su reparto de modelos tributarios y de sus hábitos de imputación. No hay base para extrapolarlos a otra asesoría.
6. **El modelo de control incluye al responsable como variable.** Su finalidad es detectar anomalías de proceso, no evaluar el desempeño de personas. Se reporta por separado del modelo de planificación, que no lo incluye, y su uso queda restringido a la revisión de casos.

10. Trabajo futuro y estado de la entrega

10.1 Qué desbloquearía cada línea

Línea	Qué falta para abordarla
Extensión a contabilidad	Ejecutar los mismos scripts cambiando PIPELINE_OBJETIVO. Volumen disponible: 10.347,6 h entre Contabilidad Interna, Contabilidad Externa y Cierres. No requiere código nuevo
Extensión a rentas	Requiere una tercera campaña. Con dos (2025 y 2026) la validación temporal se reduce a un único corte
Cerrar la validación con experto	Que el experto devuelva <code>validacion_experto.csv</code> relleno. El cálculo ya está programado
Recalibrar los intervalos de M3	Estimar los cuantiles por campaña en lugar de sobre train completo, y medir de nuevo la cobertura frente al 80 % nominal
Reducir la censura del 21,74 % de negociaciones sin tiempo	Es un cambio de proceso en la asesoría, no de modelo: imputar tiempo a toda negociación cerrada

10.2 Seguridad y reproducibilidad

Las conexiones se configuran mediante un archivo `.env` que no se versiona. Antes de cada commit se ejecuta `src/_check_seguridad.py`, que busca en todo lo que se va a versionar patrones de dirección IP, cadenas de credencial y nombres de base de datos, y aborta si encuentra alguno. Los datos (`*.csv`, `*.parquet`, `*.pkl`) están excluidos del control de versiones; solo se versionan el código, los informes en markdown y las figuras.

Cada script de `src/` se ejecuta de cero sin pasos manuales:

```
py -m pip install -r requirements.txt
py src/00_descubrimiento.py
py src/01_extraccion.py
py src/02_eda.py
py src/03_dataset.py
py src/04_baselines.py
py src/05_modelos.py
py src/06_anomalias.py
```

10.3 Lo que queda pendiente

Pendiente	Estado
Repositorio independiente dedicado solo al PFM	Registrado en <code>BLOQUEOS.md</code> (B-003) con los cinco pasos exactos. Requiere crear el repositorio y purgar el historial del antiguo, acciones que no se han ejecutado
Rotación de las credenciales de acceso a la base de datos	Incluida en B-003
Validación ciega con experto	Archivo generado, veredictos pendientes

10.4 Trazabilidad de las cifras

Toda cifra de este documento procede de un script de `src/` y está en un informe de `output/`:

Sección	Script	Informe
2 Datos	<code>01_extraccion.py</code>	<code>RESUMEN_extraccion.md</code>
3 Calidad	<code>02_eda.py</code>	<code>02_informe_calidad.md</code>
4 Metodología	<code>03_dataset.py</code>	<code>03_diccionario_datos.md</code>
5 Baselines	<code>04_baselines.py</code>	<code>04_baselines.md</code>
6 Resultados y 7 Explicabilidad	<code>05_modelos.py</code>	<code>05_modelos.md</code>
8 Anomalías	<code>06_anomalias.py</code>	<code>06_anomalias.md</code>

Las decisiones tomadas durante la ejecución, con su alternativa descartada, están en `DECISIONES.md` (D-001 a D-013). Los puntos en los que la realidad contradijo lo previsto, en `BLOQUEOS.md` (B-001 a B-004).